

世界モデル入門

AIは『頭の中』で未来を試せるか

知覚し
表現し
想像し
行動する

—
世界を心の中に描く
AIの新しいかたち

JEPA

Dreamer

Physical AI

VLA

Cosmos

Representation

encode
the world

Prediction

what will
happen next?

Simulation

imagine
alternative futures


Planning

search
better paths

Action

from imagination
to the real world

same world
many possible futures



aokikenichi & ChatGPT 著

a richer world
for
richer intelligence.

目次

はじめに　なぜ今、世界モデルなのか	5
0.1 次の単語から、次の世界へ	5
0.2 AI agentが必要とする「行動の結果」	5
0.3 Physical AIが突きつける問題	5
0.4 本書で扱う範囲	6
第1章　世界モデルとは何か	8
1.1 頭の中で試してから動く	8
1.2 観測は世界そのものではない	8
1.3 内部状態と潜在状態	9
1.4 予測と行動	9
1.5 predictionとinference	9
1.6 「World」は誰の世界か	9
1.7 2～3文で説明する	10
第2章　世界モデルを理解するための最低限のAI	12
2.1 ニューラルネットワークは関係を近似する	12
2.2 encoderは観測を内部表現へ変える	12
2.3 潜在表現は「小さくする」だけではない	12
2.4 自己教師あり学習	13
2.5 強化学習の最小像	13
2.6 model-freeとmodel-based	13
2.7 MDPとPOMDPの直感	14
第3章　世界モデルの全体地図	16
3.1 まず「何をするか」で見る	16
3.2 次に「どう実現するか」で見る	16
3.3 大きな研究の流れ	17
3.4 この地図の使い方	19
第4章　世界モデル研究の発展	20
4.1 World Models以前	20
4.2 Ha & SchmidhuberのWorld Models	20
4.3 PlaNetからDreamerへ	22
4.4 JEPA：生成せずに表現を予測する	23
4.5 generative / interactive world models	25
4.6 object-centric / structured world models	27
4.7 第4章のまとめ	29
第5章　世界モデルをコードで体験する	30
5.1 実習の狙い	30
5.2 Toy Worldの仕様	30

5.3	ステップ1：実環境からデータを集める	34
5.4	ステップ2：dynamics modelを学習する	35
5.5	ステップ3：一歩先の予測を確かめる	36
5.6	ステップ4：モデルだけで未来を展開する	37
5.7	ステップ5：複数の行動列を試す	39
5.8	ステップ6：現実へ一歩戻す	41
5.9	何が省略されているか	41
5.10	実装結果・再現性確認	42
第6章	世界モデルは何に使われるのか	44
6.1	世界モデルはRLの部品だけではない	44
6.2	Robotics / Physical AI	44
6.3	autonomous driving	46
6.4	Game / Interactive Environments	46
6.5	synthetic data generation	46
6.6	scientific discoveryとGUI agent	47
6.7	Multi-agent / Social Simulation	48
6.8	「使える」とは何か	48
第7章	脳も世界モデルを持つのか	49
7.1	別の入口から「予測する内部モデル」へ	49
7.2	Predictive Coding	49
7.3	Free Energy Principle	50
7.4	Active Inference	51
7.5	機械学習world modelとの交差	51
7.6	脳は世界モデルを持つのか	52
第8章	世界モデルをどう評価するか、何がまだできないのか	53
8.1	評価は「何を主張したか」から始める	53
8.2	予測精度と状態精度	53
8.3	visual fidelityとphysical consistency	53
8.4	action consistency	54
8.5	long-horizon consistency	54
8.6	generalizationとdistribution shift	55
8.7	相関、因果、counterfactual	56
8.8	planning utility	56
8.9	general world modelは可能か	56
8.10	未解決問題	57
8.11	本書の結論	59
Appendix		60
A.	実行環境・付属実装	60
C.	原論文ロードマップ	60

D. 基幹サーベイ	62
E. 公開形態ラベル	62
編集後記	64
改訂履歴	66
参考文献	67

はじめに なぜ今、世界モデルなのか

0.1 次の単語から、次の世界へ

生成AIの代表である大規模言語モデルは、与えられた文脈に続くトークンを予測することで、文章を書き、質問に答え、コードを生成します。この説明だけを聞くと、「次の単語を当てるだけで、なぜこれほど多くのことができるのか」と不思議に感じるでしょう。大量のテキストの規則性を学ぶ過程で、モデル内部には概念・関係・手順などを反映した表現が形成されます。ただし、それを一貫した世界モデルの保有と同一視はできません。

では、AIが文章を書くのではなく、机の上のカップをつかむとしたら何が必要でしょうか。カメラに映るカップを認識するだけでは足りません。腕をどの方向へ動かすと、手先がどこへ移るのか。カップに触れたとき、倒れるのか、滑るのか、つかめるのか。持ち上げた後に手を緩めると何が起きるのか。AIは、行動する前に少なくとも短い未来を予測しなければなりません。

ここで焦点は、「次の単語」から「次の世界の状態」へ移ります。ただし、この対比は比喻です。言語モデルにも世界についての内部表現が形成されう一方、世界モデルと呼ばれる仕組みも必ずしも映像を丸ごと予測するわけではありません。重要なのは、対象とする世界の状態変化を、エージェント自身の行動と結びつけて扱えるかどうかです。

0.2 AI agentが必要とする「行動の結果」

AI agentは、目標を受け取り、状況を観察し、行動を選び、その結果を見て次の行動を変えます。Webブラウザを操作するエージェントなら、「このボタンを押すと画面がどう変わるか」を予想します。倉庫ロボットなら、「右へ旋回すると棚との距離がどうなるか」を予想します。自動運転なら、「この速度を保ったとき、歩行者や周囲の車との関係がどう変わるか」を予想します。

反射的に一手を出すだけなら、観測から行動へ直接写像する方策でも動きます。しかし、初めての状況、複数手順の作業、安全性が重要な環境では、候補となる行動の結果を比較する能力が重要になります。世界モデルは、現実で失敗を繰り返す代わりに、内部で未来を試すための装置になります。

0.3 Physical AIが突きつける問題

Physical AIとは、物理世界を感知し、推論し、行動するAIシステムを広く指す言葉です。ロボット、自動運転車、ドローンなどが代表例です。物理世界には、言葉だけの環境にはない厳しさがあります。摩擦、遅延、遮蔽、故障、対象物の重さ、センサー雑音、他者の予測不能な行動があります。間違いは文章の誤字ではなく、衝突や破損につながる可能性があります。

そのためPhysical AIでは、世界モデルに次の役割が期待されます。

- 高次元のセンサー入力から、行動に必要な状態を取り出す
- 自分の行動によって状態がどう変わるかを予測する

- 現実では危険・高価・時間のかかる試行を内部で行う
- 未知の状況に対し、過去の経験を再構成して計画する
- 学習用のシナリオやデータを生成する

もっとも、本書が区別する表現、予測、物理整合性、長期一貫性、計画有用性などを、すべて高い水準で満たしたことが検証された汎用世界モデルは、まだ確認できていません。現在の研究は、表現、予測、生成、制御、ロボット学習など、異なる入口からこの目標へ近づいています。

0.4 本書で扱う範囲


本書では世界モデルを、おおむね次のように捉えます。

エージェントが観測から世界の内部状態を推論し、その状態が時間や自身の行動によってどう変化するかを予測するための内部モデル。

この定義は、モデルベース強化学習や認知ロボティクスを説明しやすい作業定義です。一方、近年は行動入力を持たない動画予測モデルや、3D世界を生成するモデルも世界モデルと呼ばれます。本書は用語を狭く固定せず、「何を表現し、何を予測し、誰の行動にどう使うのか」を毎回問い直します。

図0-1


模式図



予測対象と利用目的の違いを示す。対立する二分類ではない。

図0-2

模式図



第1章 世界モデルとは何か

1.1 頭の中で試してから動く

狭い机の上に、熱いコーヒー、ノートPC、スマートフォンが置かれているとします。コーヒーカップを右へ動かしたいとき、私たちは手を出す前に、ごく短い予測をします。右へ動かすとスマートフォンに当たりそうだ。手前へ引くとPCから離れる。取っ手を持つより胴を持つほうが安定するかもしれない。この予測は精密な物理シミュレーションではありません。それでも、行動候補をふるいにかけるには十分です。

世界モデルの直感は、この「頭の中で試す」にあります。現実世界で実行する前に、内部モデルの中で状態変化を展開します。展開した未来が目標に近いか、危険ではないかを評価し、行動を選びます。

ここで重要なのは、世界モデルが百科事典のような「世界についての知識集」だけを意味しないことです。知識は重要ですが、行動するエージェントには動的な関係が必要です。「カップは容器である」だけでなく、「この方向へ押すと移動する」「机の端を越えると落下する」といった変化を扱わなければなりません。

1.2 観測は世界そのものではない

エージェントが受け取るものを観測（observation）と呼びます。カメラ画像、LiDAR点群、関節角度、力覚、音声、温度、Web画面などが観測です。観測は世界そのものではありません。カメラには机の裏側が映らず、物体の重さも直接は映りません。センサーには雑音があり、同じ物体でも照明や角度によって見え方が変わります。

人間も同じです。閉じた箱の中身は見えませんが、持ち上げた重さや振った音から推測できます。つまりエージェントは、不完全な観測から、直接は見えない状態を推論します。

1.3 内部状態と潜在状態

画像の全ピクセルをそのまま扱う代わりに、世界の重要な情報をモデル内部の表現へ変換します。本書では、予測に用いるこの学習表現を潜在状態（latent state）と呼びます。潜在という語は「観測から直接見えない」という意味です。環境側のstateそのものとは区別し、必ず小さな低次元ベクトルになるとは限りません。

自動運転の例なら、潜在状態には「前方車との距離」「相対速度」「信号の状態」「道路形状」「遮蔽の背後に歩行者がいる可能性」など、次の状態や行動判断に役立つ情報が埋め込まれているかもしれません。実際のニューラルネットワークでは、それが人間に読める項目名を持たない数百次元のベクトルで表されることもあります。

良い潜在状態は、単に画像をきれいに再現できる表現とは限りません。壁紙の模様は画像再現には重要でも、ロボットの移動計画には不要かもしれません。反対に、画面では数ピクセルしかない小さな障害物が、安全な行動には決定的です。何を残し、何を捨てるかは、世界モデル設計の中心問題です。

1.4 予測と行動

時刻 t の潜在状態を z_t 、行動を a_t とすると、最小限の状態遷移は次のように書けます。

$$z_{t+1} = f(z_t, a_t)$$

これは、「現在の内部状態 z_t で行動 a_t をすると、次の内部状態 z_{t+1} がどうなるか」を関数 f で表すという意味です。実世界には不確実性があるため、実際には一つの答えではなく、複数の可能性と確率を予測することもあります。

行動を条件に含める点は重要です。動画を見て次のフレームを当てるだけなら、世界が自然にどう動くかは学べます。しかしロボットが計画するには、「何もしなければ」と「押せば」と「持ち上げれば」の違いを予測する必要があります。この性質をaction-conditioned、すなわち行動条件付きと呼びます。

ただし、行動条件付きでないモデルをすべて世界モデルから除外すべきだという合意ありません。自然動画から物理や動作の規則性を学ぶモデルは、後から少量のロボットデータで行動条件付きに拡張できる場合があります。V-JEPA 2は、行動入力なしの大規模な動画・画像で事前学習し、その後ロボット軌跡でV-JEPA 2-ACという行動条件付きモデルへ追加学習する例です。(文献18)

1.5 predictionとinference

本節では、予測 (prediction) は、内部状態から観測や次の状態を見積もる向きです。推論 (inference) は、観測から内部状態を見積もる向きです。機械学習実務でinferenceが学習済みモデルの実行一般を指す用法とは区別します。

- 推論：画像を見て「カップが机の端に近い」「手前に障害物がある」という内部状態を作る
- 予測：その内部状態と行動から「右へ押すと落ちる可能性が高い」と見積もる

Taniguchi et al.は、静的な関係を、観測 x と潜在状態 z の間の二方向として整理しています。

$$\text{prediction: } x \sim p(x | z)$$

$$\text{inference: } z \sim q(z | x)$$

時間と行動が入ると、状態遷移 $p(z_t | z_{t-1}, a_{t-1})$ 、観測生成 $p(x_t | z_t)$ 、履歴からの状態推論 $q(z_t | x_{1:t}, a_{1:t-1})$ へ広がります。本書では式を導出しませんが、「見えたものから状態を推論する向き」と「状態から見えるものや未来を予測する向き」を分けると、多くの論文を読みやすくなります。

1.6 「World」は誰の世界か

世界モデルのWorldは、宇宙の完全なコピーを意味しません。ロボット掃除機と料理ロボットでは、同じ部屋でも必要な世界の切り取り方が違います。掃除機には床の段差や通行可能領域が重要です。料理ロボットには容器、食材、温度、衛生状態が重要です。

この見方は、生物学者ヤーコプ・フォン・ユクスキュルのUmwelt（環世界）とつながります。環世界とは、生物が自身の感覚器官と行為能力を通じて経験する、その生物に固有の世界です。ダニ、人間、ロボットは同じ物理環境に

いても、感知できるもの、価値を持つもの、可能な行為が違います。(文献45)

したがって世界モデルは、神の視点から作る客観世界の完全地図ではなく、エージェントが感じ、予測し、行動するためのモデルです。この観点に立つと、身体内部の状態や社会的な相手も「世界」に含めます。


1.7 2～3文で説明する

本章の内容を短くまとめると、次のようになります。

世界モデルは、エージェントが観測から世界の内部状態を推論し、その状態が時間や行動によってどう変わるかを予測するモデルです。予測した未来を内部で試すことで、現実に行動する前に候補を比較し、計画に利用できます。ただし、何を世界モデルと呼ぶか、どこまでの機能を要求するかは研究分野によって異なります。

図1-1


模式図



破線：任意の観測生成経路。decoderを持たない方式もある。

図1-2

模式図



観測から隠れた状態へ。状態から観測や将来状態へ。

同じ部屋でも、感覚と行動可能性が違う



同じ室内配置。太枠＝そのエージェントが重視する対象の例。

第2章 世界モデルを理解するための最低限のAI

2.1 ニューラルネットワークは関係を近似する

ニューラルネットワークは、入力と出力の複雑な関係を、多数のパラメータを持つ関数として学習します。画像分類なら画像からラベルへ、言語モデルならトークン列から次のトークンへ、ダイナミクスモデルなら現在状態と行動から次状態へ写像します。

世界モデルを読むうえでは、ネットワークの層数や活性化関数より、「何を入力し、何を出力させ、どの誤差を小さくするか」を先に確認することが重要です。同じTransformerや拡散モデルを使っている、未来フレームを生成するのか、潜在表現を当てるのか、報酬を予測するのかで、世界モデルとしての役割は変わります。

2.2 encoderは観測を内部表現へ変える

encoderは、高次元の観測を内部表現へ変換する部品です。たとえば64×64のRGB画像には12,288個の数値があります。圧縮型のencoderでは、これを数十～数百次元のベクトルへ変換し、位置、速度、物体、接触状態などの予測に有用な特徴を残します。

decoderは逆方向に、内部表現から画像などを再構成します。HaとSchmidhuberのWorld Modelsでは、VAEのencoderで画像を潜在ベクトルへ圧縮し、decoderで画像に戻せるよう学習しました。一方、JEPA系では、ピクセルへの再構成を必須とせず、表現空間で予測を一致させます。decoderの有無は、研究を見分ける有力な手がかりです。(文献7・15・16・17)

2.3 潜在表現は「小さくする」だけではない

潜在表現の目的を、単なるデータ圧縮と考えると本質を見失います。世界モデルが必要とするのは、未来を予測し、行動を選ぶのに役立つ圧縮です。

迷路の画像を考えます。壁の細かな模様や光の反射を完全に保存すれば、画像はきれいに再現できます。しかし、ゴールへ行くためには、自分の位置、向き、壁、通路、ゴールの相対関係が重要です。良い潜在表現は、タスクに不要な変化には鈍感で、行動結果を左右する小さな違いには敏感でなければなりません。

ここには避けられない緊張があります。

- 観測を忠実に再現する表現は、細部を多く保持する
- 計画に効率的な表現は、不要な細部を捨てる
- 汎用的な表現は、将来どのタスクで必要になるか分からないため、捨てるべきでない

Dreamerは潜在空間で未来を展開することで計算効率を上げます。MuZeroは観測の再構成より、報酬・価値・方策など計画に必要な量を予測します。JEPAは予測困難で細かいピクセルをすべて生成せず、抽象度の高い表現の予測を狙います。同じ潜在状態でも、残したい情報が違うのです。(文献10・13・15)

2.4 自己教師あり学習

自己教師あり学習は、人が正解ラベルを付けなくても、データの一部を別の部分から予測する課題を作って学ぶ方法です。文章の一部を隠して当てる、画像の隠れた領域の表現を当てる、動画の過去から未来を当てる、といった課題があります。

世界は大量の教師信号を自然に生みます。時刻 t の画像、行動 a_t 、時刻 $t + 1$ の画像があれば、「この行動の後に何が起こったか」が学習例になります。ただし観測データだけでは、ある出来事が本当に行動の結果なのか、偶然同時に起きたのかを切り分けにくい問題が残ります。

2.5 強化学習の最小像

強化学習では、エージェントが環境を観測し、行動を選び、報酬を受け取ります。目標は、一回の報酬を最大にすることではなく、将来まで含む累積的な報酬を大きくする方策を学ぶことです。

- ・ 状態または観測：いま何が起きているか
- ・ 行動：エージェントが選べる操作
- ・ 報酬：その結果がどれだけ望ましいかを示す信号
- ・ 方策：状態や観測から行動を選ぶ規則
- ・ 価値：その状態から将来どれだけ報酬を得られそうかという見積もり

報酬は「正解ラベル」とは違います。チェスでは勝敗が最後まで分からず、ロボット操作では目標達成までの各動作に細かな正解が与えられないことがあります。どの行動が後の成功に寄与したかを学ぶ必要があります。自己教師あり学習と強化学習は、必ずしも排他的な分類ではありません。Dreamerでは、経験データから世界モデルを更新する学習と、そのモデル内で想像した軌道からactorやvalueを学ぶ強化学習が同じエージェント内に共存します。世界モデルは報酬の予測なども学ぶため、その学習全体を自己教師ありと一括して扱うことはできません。(文献10)

2.6 model-freeとmodel-based

model-free強化学習は、環境がどう変化するかを明示的に学ぶことを必須とせず、良い行動や価値を直接学びます。繰り返し経験できる環境では強力ですが、試行回数が多くなりやすく、なぜその行動の先が良いかを内部で展開する仕組みは持たない場合があります。

model-based強化学習は、環境の変化を表すモデルを使います。モデルが既知なら、その中で候補行動を試せます。未知なら、経験からモデルを学習します。現実との接触が高価なロボットでは、少ない実試行から多くの内部試行を作れることが魅力です。

ただし、モデルを使えば常に有利とは限りません。学習したモデルが少しずつ間違っていると、長いrolloutで誤差が累積します。さらに、プランナーはモデルの弱点を突く行動を見つけることがあります。モデルの中では高得点なのに、現実では失敗する「モデル搾取」です。

2.7 MDPとPOMDPの直感


MDPはMarkov Decision Process（マルコフ決定過程）、POMDPはPartially Observable Markov Decision Process（部分観測マルコフ決定過程）の略です。MDPでは、現在状態が未来予測に必要な情報を要約していると考えます。迷路で現在位置と向きが完全に分かれば、次の移動を予測するのに全履歴は不要です。

しかし実世界では、状態を完全には観測できません。カメラの外、遮蔽の背後、物体内部、他者の意図は見えません。これを部分観測性と呼び、POMDPはその状況を扱う枠組みです。エージェントは観測履歴と行動履歴から、「世界はいまどの状態にある可能性が高いか」という、隠れた環境状態についての確率分布である信念状態（belief state）を更新します。

RNNやRSSMのように履歴をまとめる仕組みが世界モデルで使われるのは、この部分観測性に対応するためです。直前の一枚だけでなく、それまで何を見て何をしたかを内部状態に折り込む必要があります。ただし、履歴から学んだlatent stateが、この確率分布をそのまま表すとは限りません。


図2-1

模式図




色や模様などの視覚的細部をすべて保存することが目的ではない。

model-free RL



model-based RL



model-freeも内部表現を持ちうる。下段は環境遷移モデルで未来を試す。

表2-1 世界モデルを読むための最低限の用語

用語	本書での短い意味	論文で確認する点
observation	センサーや画面から得る観測	状態そのものか、部分観測か
state	未来予測に必要な環境側の状態	環境側の状態とモデル内部の表現を区別しているか
latent state	モデル内部で予測に使う学習表現	連続／離散、確率的／決定論的、beliefとの関係
encoder	観測を表現へ変換するモデル	何を入力し、どの目的で学習するか
decoder	表現から観測を再構成・生成するモデル	本当に必要か、計画だけなら省けるか
dynamics model	状態変化を予測するモデル	行動条件付きか、何ステップ予測か
policy	状態から行動を選ぶ規則	モデル内想像で学ぶか、オンライン探索か
rollout	モデルまたは環境で状態を複数ステップ展開すること	真の環境か学習モデルか
planning	候補となる未来を比較して行動を決めること	探索、最適化、学習済み方策のどれか
reward / value	望ましさの即時信号／将来見込み	外部定義か、学習するか

表2-1の出典：Sutton & Barto (2018)、Hafner et al. (2019, 2020)、Taniguchi et al. (2023) を踏まえ、本書用に整理（文献3・5・9・10）。

第3章 世界モデルの全体地図

3.1 まず「何をするか」で見る

世界モデル研究が分かりにくい最大の理由は、同じ言葉が異なる機能を指すからです。ある論文は良い表現を学ぶことを目標にし、別の論文は未来映像の生成を目標にし、さらに別の論文はロボット制御の成績で評価します。そこで、モデル名より先に「そのモデルは何をするのか」を見ます。

Ding et al.は、世界モデルの機能を大きく「世界を理解すること」と「未来を予測すること」から整理しています。ここでの理解は、人間の意識的理解を意味するとは限りません。観測を内部表現へ変え、環境の構造や規則性を後続処理に使える形で保持することです。未来予測は、状態や観測が次にどうなるかを生成・推定することです。

本書では、その先を次の五段階で捉えます。

1. **representation**：高次元の観測を、重要な内部状態として表します。
2. **prediction**：時間や行動による次の状態を予測します。
3. **simulation / imagination**：予測を複数ステップつなぎ、ありうる未来を展開します。
4. **planning**：複数の未来を目標・報酬・制約に照らして比較します。
5. **action**：選んだ行動を現実または外部環境で実行し、結果で状態を更新します。

すべての研究が五段階を備えるわけではありません。I-JEPAは主に表現学習です。Soraは高品質な観測生成を示しますが、エージェントの行動候補を比較するプランナーではありません。Dreamerは表現、予測、潜在空間での想像、方策学習を一つのエージェントに組み込みます。この違いを明示すれば、「どれが本当の世界モデルか」という語義争いの多くを、機能比較へ変えられます。(文献10・16・23)

3.2 次に「どう実現するか」で見る

Dong et al.は、2026年時点の研究を、観測レベル生成、潜在空間、強化学習ベース、物体中心という四つの枝で整理しています。この分類は研究を探す索引として便利です。しかし、排他的な四流派ではありません。

Dreamerは潜在空間で状態遷移を学ぶと同時に、強化学習で方策を学びます。Genie 2は将来の観測を生成しますが、内部ではオートエンコーダの潜在フレームと潜在拡散モデルを使います。OP3は物体中心の潜在表現を、モデルベース強化学習に利用します。一つのモデルが複数の性質を持つのは当然です。(文献10・21・27)

したがって、本書では四分類を「箱」ではなく、次の複数軸として読み替えます。

- ・ **出力空間**：ピクセルなどの観測を生成するか、潜在表現を予測するか
- ・ **状態構造**：一つのベクトルか、空間グリッドか、物体・関係に分解するか
- ・ **行動条件**：行動を入力するか、潜在行動を発見するか、行動を使わないか
- ・ **学習目的**：再構成、特徴予測、報酬・価値予測、方策最適化のどれか
- ・ **利用方法**：表現抽出、オープンループ生成、計画、方策学習、データ生成のどれか
- ・ **時間幅**：一ステップ予測か、短期rolloutか、長期に一貫した世界か

同じモデルでも、どの軸を見るかで別の顔が見えます。分類にモデルを押し込めるのではなく、設計上の選択を記述することが重要です。

3.3 大きな研究の流れ

深層学習時代の世界モデル研究の大きな転換点が、2018年のHaとSchmidhuberによるWorld Modelsです。ただし、世界モデルという発想そのものが2018年に突然生まれたわけではありません。制御理論は、対象の状態とダイナミクスをモデル化し、将来を予測して入力を決めてきました。AIのプランニングは、行動が状態をどう変えるかを記述して計画しました。強化学習でも、環境モデルを学び、実経験とモデル内経験を組み合わせる研究が長く続いています。

1948年のTolmanの「認知地図」は、生物が刺激への反射だけでなく、環境の構造を内部に持つという考えを広めました。1960年前後から状態空間モデルやカルマンフィルタ、後にはモデル予測制御が、観測から隠れた状態を推定し、未来を予測して制御する工学的基盤を整えました。1990年代には、モデルを学習と計画に組み込むDynaや、再帰型ネットワークによる予測モデルを方策学習に使う研究が現れています。(文献6・43・44)

2010年代に深層学習が画像表現を大きく進めると、ピクセルから潜在状態とダイナミクスを同時に学ぶ道が開けました。2018年のHaとSchmidhuberのWorld Modelsは、VAE、RNN、controllerを分け、VizDoomのTake Cover実験で、圧縮された夢の中で方策を訓練できることを印象的に示しました。この研究が、現在「World Models」という固有名詞で語られる潮流の再注目点です。(文献7・8)

2018年にプレプリントが公開され、ICML 2019に掲載されたPlaNetは、ピクセルから学んだ潜在ダイナミクス上でオンライン計画を行いました。Dreamerはそのモデルを引き継ぎながら、毎回のオンライン探索ではなく、潜在想像の中で方策と価値を学ぶ方向へ進みます。DreamerV2は離散潜在表現でAtariへ、DreamerV3は共通のハイパーパラメータ設定で多様な領域へ広がりました。(文献9・10・11・12) 図3-1では代表的な系列をDreamerV3までのノードで示しますが、潜在世界モデル/latent model-based RLが2023年で終了したという意味ではありません。2025年のFLAREやLaDi-WMのように、潜在未来予測をロボット方策へ接続する研究も続いています。ただし、これらをDreamerV3の直接後継とは扱いません。(文献40・41)

同時期には、MuZeroのように、画面を再構成せず、計画に必要な報酬・価値・方策を予測する学習モデルも強い成果を示しました。ここから得られる教訓は、「良い世界モデルは世界を写實的に復元すべきだ」とは限らないということ。(文献13)


2022年、LeCunはポジションペーパー“A Path Towards Autonomous Machine Intelligence”で、階層的なJEPAを含む自律知能アーキテクチャを提示しました。2023年のI-JEPA、2024年のV-JEPA、2025年のV-JEPA 2へと、ピクセル生成ではなく抽象表現を予測する研究が具体化します。2026年にはV-JEPA 2.1へ拡張されました(文献35)。ただしI-JEPAは静止画像の自己教師あり表現学習であり、それだけで行動可能な動的な世界モデルが完成したわけではありません。(文献15・16・17・18)

2023年以降、動画生成の大規模化が別の流れを加速します。GAIA-1は運転映像・テキスト・行動から運転シナリオを生成し、Genieはラベルなしゲーム動画から潜在行動と生成可能な環境を学びました。2024年のSoraは、大規模動画生成が物理世界のシミュレータへつながる可能性を提起しました。Genie 2、Genie 3、World Labs Marbleは生成・対話・3D空間へ範囲を広げ、NVIDIA CosmosはPhysical AI向けWorld Foundation Modelとして大規模事前学習モデルを用途別の世界モデルへ適応する流れを明示しました。(文献19・20・21・22・23・24・25)


これと別に、認知科学・神経科学では、上位からの予測と下位からの予測誤差で知覚を説明するPredictive Coding、知覚・学習・行動を変分自由エネルギー最小化から捉えるFree Energy Principle、行動選択まで含むActive Inferenceが発展しました。この系譜はDreamerの別名ではありません。数学的道具や「予測する内部モデル」という問題意識が交差する隣接系譜です。（文献29・30・31・32）

図3-1

研究地図（初公開年）



年＝初公開年（年の間隔は非等間隔）。同じ年のノードは同じ帯に配置。
 実線矢印＝指定6本の直接継承。同じ列は概念的な近さであり、直接継承ではない。
 初公開形態：P paper / p preprint / R RA・企業技術報告 / X prototype。淡青＝Cosmos WFM系列。



二重枠＝RLを組み込む設計。RL-basedを独立した実現方式の行にはしない。

帯＝本書で扱う機能範囲。排他的分類・性能順位・直接継承を示さない。

3.4 この地図の使い方

新しい「世界モデル」が発表されたら、名称や宣伝文句より、次の質問をしてください。

- 1. 観測、状態、行動、予測対象は何か。
- 2. 行動条件付きか。行動は実際の制御信号か、潜在行動か。
- 3. ステップ予測を何回つなげるのか。長期誤差をどう扱うか。
- 4. ピクセル、潜在特徴、物体、報酬・価値の何を正しくしたいのか。
- 5. 表現評価、生成品質、物理整合性、計画成功率のどれで評価したか。
- 6. 査読論文、プレプリント、技術報告、製品デモのどれか。

この六問があれば、モデル名が毎月増えても研究地図を失いません。

第4章 世界モデル研究の発展

4.1 World Models以前

4.1.1 既知モデルで予測して制御する

制御の基本形は古くからモデルベースです。工場のプロセス、航空機、ロボットアームなどについて、現在状態と入力から次状態を計算できれば、目標に近づく入力を選べます。モデル予測制御（MPC）は、有限の時間幅で入力列を試し、最も良い列の最初の実行し、次の観測で再計画します。

この発想は世界モデルによる計画とほぼ同じです。違いは、従来は運動方程式や同定モデルが人間により与えられることが多かったのに対し、現代の世界モデルは高次元観測から表現とダイナミクスをデータ駆動で学ぶ点にあります。

4.1.2 モデルを学ぶ強化学習

環境モデルが未知なら、経験した遷移 (s_t, a_t, r_t, s_{t+1}) から学べます。学習モデルで作った仮想経験を実経験と組み合わせるDynaの考え方は、現代のimagination rolloutの明確な先祖です。（文献6）

しかし、画像を入力とする複雑な環境では二つの難題がありました。第一に、画像から計画に必要な状態を抽出すること。第二に、わずかな予測誤差が複数ステップで膨らむことです。2010年代の深層表現学習と生成モデルが、この二つへ新しい道具を与えました。

4.2 Ha & SchmidhuberのWorld Models

2018年のWorld Modelsは、世界モデルという言葉で深層学習コミュニティに強く印象づけました。構造はV、M、Cの三部品です。（文献7・8）

4.2.1 V：Vision Model

VAE（Variational Autoencoder）が各画像を潜在ベクトル z へ圧縮します。車の位置、道路の曲がり、障害物などが、画素より小さな表現へ折り畳まれます。VAEは z から画像を再構成する学習も行うため、観測の重要な特徴を保持するよう促されます。（文献7・8）

4.2.2 M：Memory Model

MDN-RNNが、現在の潜在状態 z_t 、行動 a_t 、RNNの記憶 h_t から、次の潜在状態 z_{t+1} の確率分布を予測します。MDNは混合分布を出力できるため、同じ状況から複数の未来がありうる不確実性を表せます。RNNの隠れ状態は、直前の一枚だけでは見えない時間情報を保持します。（文献7・8）

4.2.3 C : controller


controllerは、 z_t と h_t から行動を出します。驚くほど小さな線形モデルでも機能しました。VとMが環境の表現と予測を引き受けるため、方策は簡単にできるという設計です。CarRacingでは、controllerは勾配法ではなく、元のCarRacing環境の報酬を使う進化戦略で最適化されました。(文献7・8)

一方、VizDoomのTake Cover実験では、学習済み世界モデルが作る「夢」の仮想環境内だけでcontrollerを最適化し、元のVizDoom環境で評価しました。ここで元の環境はゲーム・シミュレータであり、物理的な現実世界ではありません。世界モデルが単なる特徴抽出器ではなく、方策を育てる仮想環境になったのです。(文献7・8)

同時に限界も明確でした。対象は比較的限定されたゲーム環境で、VAEとRNNは別々に学習されました。世界モデルの穴をcontrollerが利用すると、夢の中だけで成功する方策になります。VizDoomで生成温度を上げて夢を難しくする工夫は、モデルの不確実性や搾取への初期的な対策と読めます。(文献7・8)

図4-1

模式図



[学習] V : 画像を圧縮する表現、M : 次の潜在状態の分布を学ぶ。

[利用] C : (z, h) から行動を選ぶ。上段の実線は利用時の情報フロー。

次の z は環境の再観測を符号化、または夢内では予測分布から得る。

4.3 PlaNetからDreamerへ

4.3.1 PlaNet：潜在空間でオンライン計画する

PlaNet（2018年プレプリント、ICML 2019）は、画像から潜在ダイナミクスを学び、その中で行動列を試す純粋なモデルベースエージェントです。中心はRecurrent State-Space Model（RSSM）で、履歴を保持する決定論的成分と、未来の不確実性を扱う確率的成分を組み合わせます。現在状態は実観測を使って更新し、そこから先のrolloutは、まだ得られていない未来の実観測を入力せず、モデルの遷移予測だけで進めます。（文献9）

行動時には、候補となる行動列を多数生成し、それぞれを潜在空間でrolloutして予測報酬を計算します。良い候補へ分布を絞るcross-entropy methodで行動列を改善し、最初の行動だけ実行して再計画します。これは学習した潜在モデルを使うMPCです。

4.3.2 Dreamer：想像の中で方策を学ぶ

PlaNetは毎ステップ探索するため、行動時に計算が必要です。Dreamer（プレプリント2019、ICLR 2020）は、RSSMで作る潜在軌跡の中でactorとvalueを学びます。actorは行動を提案し、valueはその先の見込みを評価します。実観測から推定した潜在状態を出発点に、想像中は未来の実観測を入力せず、画像の生成も介さずに未来を展開できるため、多数の想像経験を効率よく作れます。（文献10）


ここで最も重要な語が**latent imagination**です。画像を一枚ずつ描いてから判断するのではなく、圧縮された内部状態のまま未来を進めます。読者が第5章で体験するrolloutは、この仕組みの最小版です。

4.3.3 DreamerV2とDreamerV3

DreamerV2（2020年プレプリント、後にICLR 2021）は、潜在状態を離散表現にし、Atari 55ゲームで世界モデル内の予測だけから行動を学ぶ強さを示しました。連続制御だけでなく離散的で複雑なゲームへ広げた点が重要です。（文献11）

DreamerV3は2023年にプレプリントとして公開され、2025年にNatureに掲載されました。Nature掲載版では、正規化や変換、損失バランスなどの安定化によって、共通のハイパーパラメータ設定で150を超える多様なタスクに適用し、Minecraftで人間データやカリキュラムなしにダイヤモンドを獲得しました。これは、一つの学習済み重みが追加学習なしに全タスクを解くという意味ではありません。派手な新部品というより、異なる領域で調整を減らす堅牢化が研究上の中心です。（文献12）

Dreamer系列を「未来動画を生成するモデル」と理解すると外します。観測再構成は学習を支えますが、方策改善の主舞台は潜在状態です。目的は美しい映像ではなく、行動に有用な想像です。



実線＝状態・予測の流れ。破線＝学習への利用。未来動画の生成を介さない。

4.4 JEPA：生成せずに表現を予測する

4.4.1 2022年の構想が起点

JEPAの出発点はI-JEPAではなく、LeCunが2022年に示した自律機械知能の構想です。そこでは、知覚、世界モデル、短期記憶、actor、costなどを備えた自律エージェントの構想と、複数の抽象度・時間尺度で予測し計画する階層的JEPAが提案されました。これは実験結果を報告する通常の査読論文ではなく、研究計画を示す立場表明です。(文献15)

4.4.2 ピクセルを全部当てない理由

未来画像のピクセルを予測しようとする、予測不能な細部に多くの能力を使います。木の葉の揺れ、雲の形、テクスチャの微細な変化は、正確には当てられません。平均二乗誤差で一つの未来を当てるとぼやけ、生成モデルで多様性を扱うと計算が重くなります。

JEPAは、入力xの表現から、別の入力yの表現を予測します。比較するのはピクセルそのものではなく、encoderが作る埋め込みです。抽象表現なら、細部が違って「人がカップを持ち上げた」「物体が机から離れた」という予測を一致させられる可能性があります。(文献15)

4.4.3 I-JEPA、V-JEPA、V-JEPA 2

I-JEPA (2023) は、一枚の画像で、見えている大きな文脈ブロックから隠されたターゲットブロックの表現を予測します。意味的にまとまった表現を学べますが、時間発展も行動も扱わないため、本書では「JEPA構想を具体化した表現学習」と位置づけます。(文献16)


V-JEPA (2024) は動画へ拡張し、マスクされた時空間領域の特徴を予測します。公開データの約200万動画で、ピクセル再構成、テキスト、負例を使わず特徴予測だけを学習しました。動きと外観に有用な表現を示しましたが、基本形は行動条件付き制御モデルではありません。arXivでの初公開に加え、TMLRの査読掲載版があり、Meta公式codeと学習済みweightsも公開されています(文献17)。

V-JEPA 2 (参照版: arXiv:2506.09985v1、2025-06-11) は、100万時間超のインターネット動画に画像データも加え、行動入力なしで自己教師あり事前学習を行い、理解と予測を強化しました。さらにV-JEPA 2-ACでは、DROIDから62時間未満のロボット軌跡で行動条件付き予測器を追加学習し、目標画像に向かうロボットアームの計画に使用しました。論文はこの動画を「unlabeled」と呼びますが、学習には行動と手先の状態 (end-effector state) を使い、DROID元データにも言語注釈や成功情報があります。ここでJEPAは、表現学習からPhysical AIの予測・計画へ一歩つながります。2026年9月9日時点で公式code、V-JEPA 2のweights、V-JEPA 2-AC checkpointが公開されています(文献18)。


後継拡張のV-JEPA 2.1 (2026) は、dense predictive loss、deep self-supervision、画像・動画のmulti-modal tokenizerにより、密で時間的一貫性のある特徴表現を強化する方向を示しています(文献35)。

ただし、「抽象表現を予測すれば生成モデルより常に優れている」とは言えません。ロボットが接触位置をミリ単位で判断するなら、細部が重要です。生成モデルは人間が結果を検査でき、シミュレータやデータ生成にも使えます。何を捨てるべき細部とみなすかが、まさに設計問題です。

generative prediction : 観測を予測



JEPA : 表現を予測



4.5 generative / interactive world models

4.5.1 video predictionからworld simulationへ

動画予測は以前から研究されてきました。過去フレームから次フレームを生成できれば、動きや物体相互作用を学べます。しかし、初期のモデルは短時間でぼやけたり、複数の未来を平均したりしました。Transformer、離散トークン化、拡散モデル、計算規模の拡大により、長く高精細な動画を生成できるようになりました。

ここで動画生成モデルと世界モデルの境界が問題になります。テキストから自然な動画を作るモデルは、重力、遮蔽、遠近、物体の相互作用に関する統計的規則を内部に持つはずですが、しかし、映像が自然に見えることと、介入に対する結果を正しく予測できることは同じではありません。

4.5.2 Sora : 有力な仮説、未完の証明

OpenAIは2024年の技術報告で、Soraを含む大規模動画生成が「物理世界の汎用シミュレータ」へ向かう有望な道だと述べました。Soraは時空間patchの潜在表現上で拡散Transformerを学習し、高品質で長い動画生成を示しました。一方、その報告自体が、物理的相互作用、因果関係、長時間の整合性に失敗する例も示しています。また、候補となるロボット行動を制御入力として受け、結果の正しさを計画を評価するモデルとして発表されたものではありません。(文献²³)

したがって本書では、Soraを「世界モデルである」と断定せず、動画生成をスケールすることが世界シミュレーションへ到達するかを問う研究上の境界例とします。

4.5.3 Genie：動画から操作可能な環境へ

Genie（2024年、ICML査読論文）は、ラベルなしインターネット動画から時空間トークン、ダイナミクス、潜在行動を学び、入力画像などからフレーム単位で操作可能な2D環境を生成しました。行動ラベルなしで、動画中の変化を引き起こす潜在行動を発見した点が特徴です。（文献20）

Genie 2（2024年12月の企業研究発表）は、一枚の画像からキーボード・マウスで操作できる多様な3D環境を生成します。潜在フレームと行動から次の潜在フレームを自己回帰的に生成する潜在拡散モデルとして説明されています。公開ページでは最大約1分の一貫性が報告されましたが、多くの例は10～20秒であり、査読論文に基づく評価とは区別する必要があります。（文献21）

Genie 3（2025年8月の企業研究発表）は、リアルタイム対話と一貫性をさらに進めたとされています。2026年にはGenie 3を利用するProject Genieがexperimental research prototypeとして提供されました（文献36）。ここでも、公開デモの印象と、再現可能なベンチマークによる科学的評価を分けて読む必要があります。（文献22）

4.5.4 ドメイン特化と基盤モデル

World Foundation Modelは、世界モデルと別種の技術を指すというより、大規模なデータで事前学習し、複数のPhysical AI用途へ適応できるようにした世界モデルの基盤化・foundation-model化として捉えるのが分かりやすいでしょう。ただし、この語は企業や研究計画によって射程が異なり、学術的な統一定義が確立しているわけではありません。

用語	本書での整理
World Model	状態または観測と行動から、その後の状態・観測・報酬などを予測するモデル。表現学習や計画まで含む設計もある。
World Foundation Model	大規模事前学習を基盤に、複数のPhysical AI用途へpost-trainingや条件付けで適応することを目指す世界モデル。
domain-specific world model	特定のロボット、車両、作業、環境へ適応した世界モデル。基盤モデルから派生する場合も、専用データだけで学ぶ場合もある。
simulator	初期条件と入力から軌跡や観測を展開する役割。学習モデル、物理エンジン、両者の組合せのいずれでもよい。
policy / planner	観測や予測を使って行動を選ぶ役割。世界モデルとは機能上区別できるが、単一システム内で一体化することもある。

GAIA-1（2023年プレプリント）は、自動運転映像、テキスト、車両行動を離散トークン列にし、次トークン予測で運転シナリオを生成しました。行動や場面条件を細かく指定できるため、単なる動画生成より「条件に応じた未来」の性格が強くなります。（文献19）

NVIDIA Cosmosは、単一モデル名ではなく、Physical AI向けworld foundation modelsとplatformの系列です。2025年の初期Cosmosは、データキュレーション、tokenizer、事前学習済みモデル、post-training例を組み合わせ、大規模動画で学んだ基盤をロボットや自動運転向けの世界モデルへ適応するplatformとして提示されました（文献24）。

Cosmos Predict 2.5は、Text2World、Image2World、Video2Worldを一つのflow-based architectureへまとめ、未来状態の動画シミュレーションをsynthetic data、policy evaluation、closed-loop simulationへ接続します（文献37）。2026年のCosmos 3は、text、image、video、audio、actionを扱うomnimodalな枠組みへ広げ、理解・生成・

simulation・action generationを一つの系列で扱う方向を示しました（文献38）。Predict 2.5とCosmos 3はいずれも本書の基準日にはpreprintであり、発表された機能範囲と独立した科学的検証を区別して読む必要があります。

World LabsのMarble（2025年に一般提供）は、テキスト、画像、動画、粗い3Dレイアウトから編集・拡張可能な3D世界を作ります。これは時間ダイナミクスを中心とするDreamerとは違い、空間知能、3D再構成、生成、インタラクションを中心とする「世界モデル」の用法です。2026年にはWorld APIが提供され、Marble 1.1／1.1 Plusへ更新されています（文献25）。

2026年9月1日にはWorld LabsがAtlasを発表し、生成・再構成に加えてsimulationまで射程を広げましたが、企業公式発表とearly accessの段階であり、査読論文として確認された成果ではありません（文献39）。

図4-4

設計の比較（模式図）



2026：Project Genie＝Genie 3によるprototype提供。

Atlas＝再構成・space-time simulationの企業発表（RA）。

番号＝要求・設計を考える順序。性能順位・直接継承・検証済み能力の認定ではない。

研究報告・企業demo・prototype提供を区別する（2026-09-09基準）。

4.6 object-centric / structured world models

一枚の潜在ベクトルに場面全体を押し込むと、「赤いボール」「青い箱」「二つの間の距離」のような構造を明示的に扱いにくくなります。物体中心世界モデルは、場面を物体や実体に対応する複数のslotへ分解し、物体ごとの状態と関係を予測します。

C-SWMは、各物体の表現と関係をグラフニューラルネットワークで扱い、ピクセル再構成ではなく対照学習で構造化状態を学びました。OP3は、画像から教師なしに実体表現を獲得し、物体ごとの局所相互作用で予測・計画するモデルベース強化学習を示しました。Slot Attentionは入力特徴を交換可能な複数slotへ束ねる汎用部品を提供しました。(文献26・27・28)

物体中心表現には三つの期待があります。

- ・ **組合せ一般化**：学習時と異なる物体数や配置へ広がりやすい
- ・ **解釈可能性**：どの表現がどの物体に対応するか観察しやすい
- ・ **効率的推論**：変化した物体と関係だけを更新できる可能性がある

一方、現実の動画から安定して物体を分離し、遮蔽中も同じ物体として追跡し、方策学習まで成功させるのは難題です。「物体」が常に最適な単位とも限りません。液体、布、群衆、影、道路面のように境界が曖昧な対象があります。

affordanceは、物体の属性だけでなく、エージェントにとって可能な行為を表します。椅子は人間には「座れる」対象でも、小型ロボットには「下を通れる」空間かもしれません。Taniguchi et al.が強調するように、affordanceはエージェントと環境の関係であり、Umweltと物体中心表現を行動へ結びます。(文献3・45)

記号や知識グラフを神経表現と組み合わせるneuro-symbolicな方向もあります。ルールによる長期推論や説明可能性を得やすい反面、どの記号を観測から作り、変化する現実へどう接地するかが課題です。物体中心とneuro-symbolicは同義ではありませんが、構造を内部表現へ導入する接点があります。

表4-1 代表的世界モデルの比較

Model	Year	representation	prediction target	Action-conditioned	主用途	公開形態
World Models	2018	VAE潜在＋RNN記憶	次の潜在状態分布	Yes	方策進化、夢内訓練（VizDoom）	初公開Preprint／NeurIPS掲載版
PlaNet	2018/2019	連続RSSM	潜在状態・観測・報酬	Yes	潜在MPC	ICML査読論文
Dreamer	2019/2020	連続RSSM	潜在状態・報酬・価値（critic側）	Yes	潜在想像で方策学習	ICLR査読論文
DreamerV2	2020/2021	離散RSSM	潜在状態・報酬・価値（critic側）	Yes	Atari、連続制御	ICLR査読論文
DreamerV3	2023/2025	離散潜在ダイナミクス	潜在状態・報酬・継続・価値（critic側）	Yes	多領域の汎用RL	2023初公開／2025 Nature掲載版
MuZero	2019/2020	計画特化の潜在状態	報酬・価値・方策	Yes	木探索によるゲーム計画	Nature査読論文
I-JEPA	2023	画像blockの埋め込み	隠れ領域の表現	No	自己教師あり画像表現	CVPR査読論文
V-JEPA	2024	動画の時空間埋め込み	マスク領域の表現	No	動画表現・動作理解	arXiv初公開／TMLR査読／codeあり／weightsあり

Model	Year	representation	prediction target	Action-conditioned	主用途	公開形態
V-JEPA 2 / V-JEPA 2-AC	2025	大規模動画埋め込み	未来表現、ACでは行動結果	基本No／ACはYes	理解・予測・ロボット計画	arXiv v1（2025-06-11）／codeあり／weights・AC checkpointあり
GAIA-1	2023	離散 video/text/action token	次token・運転映像	Yes	自動運転シナリオ生成	arXiv技術報告
Genie	2024	動画token＋潜在行動	次の観測token	Latent action	操作可能2D環境生成	ICML 2024査読論文（arXivあり）
Genie 2	2024	潜在frame＋拡散dynamics	次の視覚観測	Yes	操作可能3D環境	企業研究発表
Genie 3	2025	非公開詳細を含む生成表現	対話的な次観測	Yes	リアルタイム生成世界	企業研究発表／2026 research prototype
Sora	2024	時空間patch潜在	動画	No（agent action なし）	動画生成、simulation仮説	企業技術報告
Cosmos initial / platform	2025	tokenizer＋AR／diffusion潜在	text・image・video条件の動画	追加学習構成でYes	Physical AI用生成・予測	arXiv技術報告／platform／codeあり／weightsあり
Cosmos Predict 2.5	2025	動画潜在＋flow-based model	未来動画・multi-view動画	基本No／robot ACはYes	future-state simulation・policy 評価	Preprint／codeあり／weightsあり
Cosmos 3	2026	複数modalityのtoken表現	text・画像・動画・音声・行動列（タスク別）	Yes（行動→未来の構成）	理解・生成・simulation・action	Preprint／codeあり／weightsあり
OP3	2019/2020	object/entity潜在	物体状態と相互作用	Yes	物体中心の予測・計画	2019初公開／CoRL 2020論文集
Marble	2025	生成3D空間表現	3D世界の生成・編集	操作は可能、行動dynamicsは要確認	空間生成・編集	企業発表／2025一般提供／2026 API・1.1・1.1 Plus

表4-1の注意：Yearは初回公開年を基本とし、査読年が異なる場合は併記しました。「Action-conditioned」は、実際のエージェント行動を条件とするかを示します。テキスト指示やカメラ条件だけを、直ちにagent actionとは数えていません。prediction targetには主要な予測・評価対象を挙げ、Dreamer系列の価値は世界モデルではなくcritic側と明記しています。各行の出典はWorld Models（文献7・8）、PlaNet～DreamerV3（文献9～12）、MuZero（文献13）、I-JEPA～V-JEPA 2（文献16～18）、GAIA-1～Marble（文献19～25）、OP3（文献27）、V-JEPA 2.1～Atlas（文献35～39）です。時間依存性の高い公開状況は2026年9月11日基準です。code、weights、製品・prototypeの提供は別の状態として記載します。Cosmosは初期platform・Predict 2.5・Cosmos 3を区別し（文献24・37・38）、複数viewの入力やカメラ制御だけを行動条件付きと扱いません。

4.7 第4章のまとめ

研究史から見えるのは、モデルの巨大化だけではありません。何を予測すべきかという問いが変化しています。

- World Modelsは観測を圧縮し、次の潜在状態を予測しました。
- PlaNetは潜在空間で行動列をオンライン計画しました。
- Dreamerは潜在想像から方策そのものを学びました。
- MuZeroは写實的再構成を捨て、計画に必要な予測へ絞りました。
- JEPAはピクセルではなく抽象表現を予測しました。
- 生成型モデルは、高精細で操作可能な観測世界を作り始めました。
- 物体中心モデルは、世界を構成要素と関係へ分けようとしています。

これらは一本の勝ち抜き戦ではありません。将来の世界モデルは、潜在予測の効率、生成モデルの可視性、物体構造の組合せ性、強化学習の意思決定を組み合わせる可能性があります。

第5章 世界モデルをコードで体験する

5.1 実習の狙い

ここまでの説明で、世界モデルが現在状態と行動から未来状態を予測することは分かりました。しかし、普通の教師あり学習と何が違うのかは、まだ曖昧かもしれません。

一組の(state, action)からnext stateを当てるだけなら、確かに回帰問題です。世界モデルらしさが現れるのは、予測したnext stateを次の入力として使い、まだ現実で観測していない未来を何ステップも展開するときです。さらに、複数の行動列をモデルの中で試し、最も良い未来を選んで現実に一歩だけ進みます。

本章では、2次元Toy Worldを使ってこの瞬間を分解します。表現学習、確率モデル、方策勾配などをいったん外し、「学習済みモデルの中で考えてから動く」という核だけを取り出します。実装・実行した結果を使って、一歩予測、長期rollout、planningを順に確認します。

5.2 Toy Worldの仕様

環境は0以上1以下の正方形です。エージェントの状態は位置 $state = (x, y)$ で表します。障害物もノイズもない Basicと、両方を加えたChallengeを用意しました。

項目	固定した仕様
状態・行動	$s (t \begin{matrix} x \\ a, 0 \\ y, \\ e \end{matrix}) 1 = \in]^2$ (float32)。0: UP、1: DOWN、2: LEFT、3: RIGHT。1 stepの基本移動量は0.05。
目標・終了	goal = (0.9, 0.9)。移動後のgoal距離が0.05以下なら成功。最大80 step。両方が重なる場合は成功を優先。

項目	固定した仕様
初期位置	各座標を独立にUniform(0 . 0 5 , 0 . 3 5)から選ぶ。すなわちreset = Uniform(0 . 0 5 , 0 . 3 5 ²)。
Basic	障害物なし・ノイズなし。移動後、 0 , 1 ²の境界でclipする。

項目	固定した仕様
Challenge	閉長方形
	0 ・ 4 , 0 ・ 6
	×
Challenge	0 ・ 3 5 , 0 ・ 6 5
	を障害物とする。各座標に独立なGaussian noise（平均0、SD 0.003）を加える。
Challengeの処理順	移動 → noise → boundary clip → 障害物判定。移動の終点が障害物内なら元位置へ戻す（線分の交差判定ではない）。

報酬は、目標への接近を評価し、歩数と障害物衝突に罰を与え、成功時に加点します。厳密には

$$r = d(s, \text{goal}) - d(s', \text{goal}) - 0.01 - 0.10I(\text{collision}) + 1.0I(\text{success})$$

です。dはユークリッド距離、s'は移動後の実状態、Iは条件が成立すると1、しなければ0です。これは実環境のrewardであり、5.7のplanner scoreとは別物です。

Challengeでは小さなノイズにより、同じ状態と行動でも結果が完全には一致しません。MSEで次状態を一つ予測する決定論的MLPは、このばらつきの分布を表しません。確率的世界モデルへ発展させる余地が見えます。

5.2.1 環境API

ToyWorldは次の独自APIを持ちます。stepのdoneは成功または時間切れで、info

”terminated”

がgoal成功、info

”truncated”

が時間切れを表します。

```

class ToyWorld:
    def reset(self, seed=None) -> np.ndarray:
        """初期状態 [x, y] を返す。"""

    def step(self, action: int):
        """next_state, reward, done, info を返す。"""


    def transition(self, state, action, noise=True):
        """任意stateの真の遷移。現在stateとstep数は進めない。"""

```

actionは整数でDynamicsModelへ渡し、モデル内部で4次元のone-hotベクトルへ変換します。状態2次元と連結するので入力6次元、出力は次状態2次元です。transitionは真値比較にも使い、noise=Falseなら環境の乱数も消費しません。

図5-1

仕様図（実装固定値・軌跡ではない）



単位正方形 $[0, 1]^2$ / 行動 step = 0.05

reset : $[0.05, 0.35] \times [0.05, 0.35]$

goal = (0.9, 0.9) / 成功半径 = 0.05

Basic : 障害物なし・ノイズなし

Challenge : 障害物 $[0.4, 0.6] \times [0.35, 0.65]$ (閉長方形)

Challenge : Gaussian noise の標準偏差 = 0.003

5.3 ステップ1：実環境からデータを集める

最初はランダム方策で環境を歩き、遷移を集めます。一件の中心は(state, action, next_state)です。今回の実装ではreward、終了・衝突の情報とtrajectory ID、時刻も保存しました。

```
from experiment import collect_dataset

# config・variant・seed・保存先rootは付属の実行設定を使う。
data = collect_dataset(config, variant, seed, root)
```

ここで収集方策がデータ分布を決めます。ランダム移動では、障害物の裏側や境界付近を十分に訪れないことがあります。世界モデルは見えていない領域を自動的に理解するわけではありません。プランナーがデータの薄い領域へモデルを押し出すと、予測が壊れる可能性があります。

主評価ではtrajectory単位でtrain、validation、testへ分けました。各環境・seedの200本を140／30／30本に分け、各trajectoryは最大60 step収集しています。transitionをランダムに混ぜる分割では同じtrajectoryの近接状態がtrain／test双方へ入り得ますが、seed11の比較ではBasicのMSEは悪化、Challengeは改善し、必ず楽観的な値になる結果ではありませんでした。

5.4 ステップ2：dynamics modelを学習する

モデルは $6 \rightarrow 64 \rightarrow 64 \rightarrow 2$ 、ReLUを使う小さなMLPです。Challengeが難しくても大型化せず、この単純なモデルの限界も観察します。次は共通実装の核心です（入力形状の検査は省略）。

```
import torch
from torch import nn
from mini_world_model import action_one_hot

class DynamicsModel(nn.Module):
    def __init__(self):
        super().__init__()
        self.network = nn.Sequential(
            nn.Linear(6, 64), nn.ReLU(),
            nn.Linear(64, 64), nn.ReLU(), nn.Linear(64, 2),
        )

    def forward(self, states, actions):
        one_hot = action_one_hot(actions).to(
            device=states.device, dtype=states.dtype)
        delta = self.network(torch.cat((states, one_hot), dim=-1))
        return states + delta
```

次状態そのものではなく、移動量deltaを予測し、現在状態へ足します。状態変化が小さい環境では、この残差形式が学びやすいことがあります。lossは予測next stateと実next stateの平均二乗誤差です。


学習は60 epochs、batch 256、Adam、学習率0.001としました。validation MSEが最小のcheckpointを採用し、testは学習やcheckpoint選択に使っていません。

```
from torch.nn import functional as F
pred_next = model(state_batch, action_batch) # action_batchは整数
loss = F.mse_loss(pred_next, next_state_batch)
```

このモデルは画像encoderを持ちません。state = (x, y) がすでに意味のある低次元状態だからです。Dreamerでは、画像観測から潜在状態を推論する部分と、その潜在状態を遷移させる部分を同時に学びます。本実習は後者だけを目に見える座標で行います。

図5-2

仕様図（実装確定）



予測後の境界clip・真の障害物規則による補正は入れない。


5.5 ステップ3：一歩先の予測を確かめる

まずtest setで一ステップ誤差を測ります。位置誤差は予測位置と真の位置のユークリッド距離です。Challengeの平均は約0.00438でした（trajectory test、5 seedの平均）。散布図に加えて空間上の誤差を色分けすると、障害物近傍では約0.00950、障害物近傍と外枠近傍を除くotherでは約0.00407という局所差が見えます。

障害物の境界では、わずかな位置差で「進める」と「止まる」が切り替わります。今回も、真の環境では止まるのにMLPは障害物へ入り込む次状態を予測した例がありました。平均誤差が小さくても、こうした局所的な失敗は隠れてしまいます。

一ステップ誤差が小さくても安心できません。その予測を次の入力へ繰り返し使ったときにも正しいかは、別に確かめる必要があります。そこで複数ステップ評価へ進みます。

図5-3



領域別平均：各seedの平均を5 seedで平均（nは全seedの総数）

領域	Basic mean	Challenge mean	n : Basic / Challenge
obstacle	NA	0.009499	0 / 641
boundary	0.000718	0.003762	3,288 / 3,308
other	0.000413	0.004067	5,712 / 5,051

近傍：距離 ≤ 0.075 。obstacleを優先 $\rightarrow$ outer boundary $\rightarrow$ other。

表示：各環境9,000件をセル内集計。領域別平均とは集計単位が異なる。

空白セルは未測定。補間なし。斜線＝障害物。濃淡・数値目盛で誤差を示す。

5.6 ステップ4：モデルだけで未来を展開する

ここが本章の中心です。初期状態 s_0 だけは実環境から得ます。その後、行動列 $[a_0, a_1, a_2, \dots]$ をモデルへ順番に入れます。

$$\hat{s}_1 = \text{model}(s_0, a_0),$$

$$\hat{s}_2 = \text{model}(\hat{s}_1, a_1),$$

$$\hat{s}_3 = \text{model}(\hat{s}_2, a_2).$$

$\hat{s}_1$ 以降は実環境から取得していません。 $\hat{s}_2$ の入力、現実の s_1 ではなくモデル自身が予測した $\hat{s}_1$ です。モデルが自分の出力を再び入力として使うことで、現実を進めずに未来を作ります。これをmodel rollout、imagined rollout、またはimaginationと呼びます。

共通関数 `learned_rollout(model, starts, actions)` は、`starts` が $(N, 2)$ 、整数 `actions` が (N, H) 、出力が $(N, H + 1, 2)$ です。次はその再帰部分の抜粋です。入力検査とdevice選択は省略しています。


```
state = torch.as_tensor(starts, dtype=torch.float32, device=device)
action_tensor = torch.as_tensor(actions, dtype=torch.long, device=device)
trajectory = [state]
with torch.no_grad():
    for t in range(actions.shape[1]):
        state = model(state, action_tensor[:, t])
        trajectory.append(state)
imagined = torch.stack(trajectory, dim=1).cpu().numpy()
```

比較のため、同じ初期状態と同じ行動列を真のToyWorld.transitionにも与えます。Challengeの真値側はnoise=Trueです。通常のreset分布から始めるIID評価では、平均位置誤差が1 stepの約0.0039から20 stepの約0.0217へ増えました。これは5 seedのrollout評価で、5.5のtest setとは評価集合が異なります。

平均だけでは、個々の破綻を見落とします。事前に定めた失敗条件に該当した例では、H1の誤差は約0.00371でも、H20では約0.369でした。止まるべき障害物衝突を一度通過できると予測すると、以後はその誤った位置から想像が続き、同じ行動列でも真の軌跡と大きく分岐します。

図5-4

実測図 (selected failure example)



same action sequence / no intermediate re-observation

seed11 / IID / probe189 / 真値はChallenge環境のnoiseあり

選択条件 : $H1 \leq 0.015$ 、 $H20 \geq 0.10$ 、真の衝突時に予測が障害物内。

該当11例中のH20最大。平均例・典型例ではない。

H1 / H20は同じ開始位置・行動列での真値との位置誤差。

保存された行動列 (20手) : 3 3 0 3 0 0 0 3 2 0 3 2 3 0 2 0 3 0 3 2

衝突時刻 (到達側horizon) : 3, 5, 6, 7, 10, 14, 16, 18

5.7 ステップ5：複数の行動列を試す

現在状態から長さHの行動列を多数サンプリングします。今回はH=10、128候補の一樣ランダムなrandom shootingです。それぞれをモデル内でrolloutし、次の4項に負の重みを掛けて合計したscoreが最大の列を選びます。これは実環境の累積rewardを計算するものではありません。

scoreの項	定義	重み
final_goal_distance	最終予測状態からgoalまでの距離	-1.0

scoreの項	定義	重み
obstacle_proximity_cost	障害物 m までの距離 d_{mx} の関数として、$\frac{1}{d_{mx} + 0.001}$ を計算し、時間平均する。Basicでは0。	-0.05
path_length_cost	$\sum_{t=1}^H \ s_t - s_{t-1}\ _2$。隣接する予測状態間の距離を足した軌跡長。	-0.02
invalid_region_cost	$\begin{bmatrix} 0 \\ 1 \end{bmatrix}$。障害物内部の指示関数と² 外部の指示関数を足し、未来位置について時間平均する。	-1.0

scoreは共通moduleのscore関数を使います。次はchoose_action内の候補比較の核心です。Nominal-dynamics MPC（診断用参照）は、Learned-model MPCと同じhorizon、候補列、候補数、score、一手実行・再計画を使い、planning modelだけをToy Worldのノイズを除いた既知の決定論的dynamicsへ置き換えた条件です。実装APIではoracle=Trueで指定します。

```

starts = np.repeat(state[None, :], len(candidates), axis=0)
if oracle: # Nominal-dynamics MPC (診断用参照)
    trajectories = oracle_rollout(env, starts, candidates)
else:
    trajectories = learned_rollout(model_or_None, starts, candidates)
all_scores = score(trajectories, env, planner_config)
best_index = int(np.argmax(all_scores))
action = int(candidates[best_index, 0]) # 最初の一手だけを実行

```

最も良い行動列を見つけても、全列を一度に現実で実行しないほうが安全です。最初の一手だけを実行し、新しい実観測を得て、再び候補列を計画します。これはreceding horizon control、すなわち後退ホライズン制御の考え方です。予測が少しずれても、毎ステップ現実に合わせて修正できます。

比較は、毎回ランダムに一手を選ぶRandom、学習した遷移で計画するLearned-model MPC、Nominal-dynamics MPC（診断用参照）の三条件です。診断用参照のplanning modelには、ChallengeでもToyWorld.transition(noise=False)を使い、将来ノイズを先読みしません。各policyは自分が到達した実状態から計画

します。Basicではこのdynamicsと実遷移が一致しますが、Gaussian noiseを含むChallengeの実遷移とは一致しません。

これにより「学習モデルをノイズを除いた既知のdynamicsへ置き換えたらどうなるか」を調べます。このノイズなし骨格は、確率遷移の厳密な条件付き平均とも同一とは限りません。ChallengeのIID開始では次の結果になりました（5 seed、各5 episode、計25 episode/policy）。

policy	成功数	成功率
Random	0 / 25	0%
Learned-model MPC	22 / 25	88%
Nominal-dynamics MPC（診断用参照）	21 / 25	84%

今回の固定条件ではLearned MPCがRandomを上回りました。ただし、この小規模実験から常に優れるとは言えず、Nominal-dynamics MPCとの差4ポイントから優劣も一般化できません。

Basic IIDでも、Random 0%、Learned MPC 100%に対しNominal-dynamics MPCは52%でした。調査で実装バグは確認されておらず、有限horizon・有限候補の探索と最終状態中心のscore、途中でgoalへ到達すると終わる実episodeとのずれが成績を制約します。Basicでは既知の決定論的dynamicsを使っている、このplannerによる良い行動は保証されません。詳しくはIMPLEMENTATION_REPORT.mdの§12~13を参照してください。

候補を一様ランダムに作ると、Hが長いほど組合せが爆発します。4行動でH=10なら1,048,576通りです。発展版ではcross-entropy method、beam search、MCTS、学習済みpolicyなどを使います。PlaNetは候補行動列をCEMで改善し、Dreamerはactorを潜在想像の中で学習して探索を置き換えます。（文献9・10）

5.8 ステップ6：現実へ一歩戻す

計画した最初の行動だけを実環境へ送り、next_stateを観測します。この実状態と予測の差を記録し、新しい実状態から再計画します。今回の主実験ではモデルの重みを固定しており、replay bufferの追加経験で行うonline retrainingは未実装の発展課題です。

全体のループは次のようになります。

1. 現在状態を観測する。
2. モデル内で複数の行動列をrolloutする。
3. 予測未来をscoreで評価する。
4. 最良列の最初の行動だけ実行する。
5. 結果を観測し、モデル予測との差を記録する。
6. モデルの重みは固定したまま、1へ戻る。

これでperception→world model→prediction→planning→action→perceptionの閉ループが完成します。

5.9 何が省略されているか

Mini World Modelは、世界モデルの核心を見せるため、多くを省略しています。

- ・ 状態(x, y)を直接与えており、画像から潜在状態を学んでいません。
- ・ 未来を一つに決める決定論的MLPで、Challengeのノイズ分布を表しません。
- ・ 報酬モデルを学ばず、goalと障害物のgeometryを既知情報としてplannerへ与え、人手でscoreを計算します。
- ・ 方策と価値を学ばず、候補行動列をその場で探索します。Nominal-dynamics MPC（診断用参照）も有限 horizon・有限候補と固定scoreに制約されます。
- ・ 障害物は固定で、他エージェントや未知の変化がありません。
- ・ モデルの信頼度が低い領域を避ける仕組みがありません。

開始位置を $x \in [0.05, 0.20]$ 、 $y \in [0.80, 0.95]$ へ変えたOOD評価も行いました。これは通常のreset分布外ですが、学習中に完全に未訪問だった領域ではありません。

Challengeでは、IIDからOODへ変えると一步の平均位置誤差は約0.00391 → 0.00559、H20は約0.0217 → 0.0583、Learned MPCの成功率は88% → 76%でした。ただし全policyで成功率が下がったわけではなく、開始位置からgoalまでの距離や経路の難しさも異なります。これは本書のToy Worldの結果であり、世界モデル研究全体を代表するベンチマークではありません。

これらを一つずつ加えると、現代の世界モデル研究へ近づきます。ただし、複雑なモデルを一度に実装するより、各機能が何を解決するのかを分けて理解するほうが重要です。

表5-1 Mini World ModelとDreamerの対応

Mini World Model	Dreamer系	本質的な違い
$s_t \text{ a (} t \text{ } x \text{ e , } = y \text{)}$	観測履歴から推論したRSSM潜在状態	Dreamerは状態表現自体を学ぶ
MLP dynamics	確率的＋決定論的な潜在dynamics	部分観測性と不確実性を扱う
next state MSE	表現・再構成・報酬・継続などの複合目的	学習信号が多い
ランダム候補列	actorが提案する行動	方策を想像内で学ぶ
手作りscore	学習したreward / value	長期的な価値を推定する
全候補rollout	大量のlatent imagination	画像を生成せず効率よく展開する
一手実行して再計画	actorで行動し経験を蓄積	方策実行と継続学習を統合する

表5-1の出典：Hafner et al.（2020, 2021, 2025）の設計を、本実習との対応に絞って整理（文献10・11・12）。

5.10 実装結果・再現性確認

Python／Notebookの実装をローカルCPUで実行し、次を確認しました。LearnedがRandomに勝つことや、OODで性能が落ちることを合格条件にはしていません。

確認項目	結果
実行環境	CPU／Python・PyTorch・NumPy・Matplotlibで確認済み

確認項目	結果
実行規模	実測ホストで主実験は数分以内（依存導入・図生成・テスト等を除く）
5 seed・one-step	学習・test評価を確認済み
H1／5／10／20 rollout	model-onlyでの評価を確認済み
failure保存	条件に該当する失敗例と元データを保存済み
3 policy planning	Random／Learned／Nominal-dynamics MPCを比較済み
OOD	事前指定の開始条件で評価済み
Notebook・Python	共通moduleを使用。Notebookはfresh kernelで実行確認済み
pytest・再現性	44件合格（既存39件＋公開導線5件）。保存結果とNotebook再実行結果の照合を確認済み
Google Colab現地確認	実行・時間測定とも未確認

Notebookはseed11の両環境を動かす教材版で、5 seedの主評価全体とは区別します。Colab向けに実行可能な構成としていますが、現地実行は未確認です。条件・再現手順・[詳細結果は付属のREADME.md](#)、[SPEC.md](#)、[IMPLEMENTATION_REPORT.md](#)へまとめています。

第6章 世界モデルは何に使われるのか

6.1 世界モデルはRLの部品だけではない

現代の世界モデルが再注目された中心にはモデルベース強化学習があります。しかし用途は、方策学習だけではありません。内部状態を作る、未来を予測する、候補を比較する、仮想環境を作る、学習データを増やすという機能は、多くの領域で使えます。

用途をモデル名で覚えるより、世界モデルがどの役を担うかで整理します。

1. **representation** : 観測を行動可能な状態へ変える。
2. **prediction** : 自然な変化と行動の結果を見積もる。
3. **planning** : 候補行動を内部で評価する。
4. **simulator** : エージェントを訓練・評価する環境になる。
5. **data generation** : 希少・危険・高価な状況のデータを作る。

6.2 Robotics / Physical AI

6.2.1 robot learning

実ロボットでの試行は遅く、高価で、危険を伴います。壊れやすい物をつかむ学習を、何十万回も失敗しながら行うことはできません。世界モデルが少量の実経験から遷移を学べれば、内部rolloutで方策を改善し、実試行数を減らせます。

DayDreamerは、Dreamerを四種類の実ロボットへ適用し、シミュレータなしに実世界でオンライン学習しました。四脚ロボットの起き上がり・歩行、二種類のアームによるpick-and-place、車輪型ロボットの視覚ナビゲーションを、同じハイパーパラメータで扱いました。重要なのは「ロボット一般が解けた」ことではなく、潜在世界モデルによる少量実経験学習が実機でも成立する強い基準線を示したことです。(文献14)

6.2.2 Manipulation

物体操作では、接触、摩擦、柔らかさ、遮蔽が問題になります。ロボットは、腕の軌道だけでなく、対象物が押され、回り、つかまれ、他物体へ接触する未来を予測しなければなりません。

世界モデルの使い方は複数あります。未来画像を生成して目標画像に近い行動を選ぶ、物体中心表現で対象の位置関係を予測する、潜在状態と報酬から方策を学ぶ、候補動作を生成モデルで可視化して検査する、といった方式です。画像がきれいでも接触点がずれていれば失敗するため、操作では視覚品質よりaction consistencyが重要になる場面があります。

V-JEPA 2-ACは、大規模な行動入力なしの動画・画像事前学習の後、行動と手先の状態を伴う少量のロボット軌跡で行動条件付き予測を学び、目標画像を用いたpick-and-place計画に使いました。Web動画の知識をそのまま制御へ使えたのではなく、ロボットの行動と結果を結ぶ追加学習が必要だった点が重要です。(文献18)

6.2.3 Navigation

ナビゲーションでは、現在位置、向き、通行可能領域、見えていない空間、移動後の視界を扱います。部分観測性が強いので、地図または記憶を内部状態へ保つ必要があります。

世界モデルは、行動後の画像や潜在状態を予測し、障害物回避や目標到達に使えます。未知環境では、知っている場所へ安全に進むだけでなく、情報を得るためにどこへ動くかという探索も必要です。予測の不確実性が高い場所へ近づいて観測を増やす行動は、単なる最短経路とは違います。

6.2.4 sim-to-realとreal-to-sim

従来の物理シミュレータは、既知の物理法則と3D資産から環境を作ります。高速で制御可能ですが、現実との差、すなわちsim-to-real gapがあります。学習型世界モデルは実データの複雑さを取り込めますが、物理保証が弱く、未経験状況で破綻します。

両者は競合するだけではありません。物理シミュレータで構造と安全制約を与え、実データから残差を学ぶ。生成モデルで見た目や条件を多様化し、物理エンジンで、定めた物理モデルに従って状態遷移を計算する。実世界ログから世界モデルを作り、失敗シナリオをシミュレータへ戻す。こうしたhybridが現実的です。

2025–2026年には、世界モデルとrobot policyを直接接続する研究が増えています。ただし接続方法は一つではありません。FLAREは未来観測の潜在表現の予測をVLA型policyの学習へ組み込み、LaDi-WMは予測した未来の潜在状態をdiffusion policyへ渡し、V-JEPA 2-ACは行動条件付きの潜在予測を計画に使います（文献40・41・18）。VLAそのものを世界モデルと呼ぶのではなく、予測モデルをpolicy learning、planning、evaluationへどう接続するかを見ることが重要です。

6.2.5 VLA、World Model、World Action Model

三つの語は、中心となる入出力で区別すると理解しやすくなります。

- **VLA (Vision-Language-Action model)**：概念的には $\text{observation} + \text{language} \rightarrow \text{action}$ を中心とする policy です。視覚と言語による指示から行動を出します。
- **World Model**：概念的には $\text{state} / \text{observation} + \text{action} \rightarrow \text{future state} / \text{observation}$ を中心とする予測モデルです。候補行動の結果を見積もり、policy learning、planning、evaluationへ渡せます。
- **World Action Model (WAM)**：world dynamicsの予測とaction generation/policyをより密接に結びつける研究方向です。予測モデルと行動モデルを段階的につなぐ構成と、両者を共同で学ぶ構成が提案されています。（文献42）

したがって、すべてのVLAがworld modelなのではなく、すべてのworld modelがVLAなのでもありません。一つのシステムやmodel familyが予測と行動生成の両方を担うことはありますが、どの機能をどの学習信号で獲得し、予測が実際の行動選択をどう改善するかを分けて確かめる必要があります。World Action Modelという語も、2026年時点で完全に固定した単一定義ではなく、文献42はこの新しい用法を整理したpreprintです。

6.3 autonomous driving

自動運転は、世界モデルの要求が分かりやすい領域です。車載カメラやLiDARから道路、車、歩行者、信号を表現し、周囲の主体がどう動くか、自車の加減速や操舵が未来をどう変えるかを予測します。

GAIA-1はvideo、text、actionをトークン列として扱い、多様な運転シナリオを生成しました。このようなモデルは、データが少ない天候、道路形状、危険場面を作る可能性があります。ただし、生成された動画が珍しいだけでは訓練価値を保証しません。センサー幾何、複数カメラ間の整合、交通規則、他車の反応、衝突判定が正しくなければなりません。(文献19)

自動運転世界モデルには少なくとも三つの用途があります。

- **予測**：現在の実走行から周囲と自車の未来を予測する
- **評価**：候補軌道をrolloutし、安全性と快適性を比較する
- **生成**：希少シナリオや条件違いを合成し、学習・検証へ使う

同じモデルが三役を担う場合もありますが、生成品質の評価だけで計画安全性を証明することはできません。

6.4 Game / Interactive Environments

ゲームは、状態、行動、報酬が明確で、失敗を安全に繰り返せるため、世界モデル研究の主要な実験場でした。World ModelsのCarRacingやVizDoom、DreamerV2のAtari、DreamerV3のMinecraftは、複雑さを段階的に上げました。(文献7・8・11・12)

近年のGenieは、既存ゲームを攻略するだけでなく、操作可能な環境自体を生成します。これにより、エージェントへ無数の未知環境を与える構想が生まれます。固定ベンチマークへ過学習せず、多様な世界で汎化を評価できる可能性があります。(文献20)

しかし、生成世界が不安定なら、エージェントの学習目標も動きます。ルールが途中で変わる、見えなくなった物体が別物として戻る、同じ行動の効果が場面ごとに変わる環境では、得た能力を現実へ移せません。世界生成とエージェント評価を同じモデルに依存させると、共通の誤りを見逃す危険もあります。

6.5 synthetic data generation

Physical AIでは、実データ収集がボトルネックです。多数のロボット、天候、故障、作業員、物体配置を網羅するのは困難です。CosmosのようなWorld Foundation Modelは、大規模動画で得た一般的な事前知識を、特定のロボットや自動運転用途へpost-trainingし、条件付き動画や学習データを生成する基盤を目指します。(文献24)

synthetic dataには、量を増やす以外の使い方があります。

- 実データに少ない危険・希少事象を増やす
- カメラ視点、照明、背景、物体配置を系統的に変える
- 同じ初期条件から行動条件を変えた複数の候補未来を生成する
- 故障やセンサー欠損を注入して堅牢性を調べる

- ・ 人間が指定した安全制約への違反例を作る

一方、生成モデルの偏りを大量複製する危険があります。合成データで学んだモデルを同系統の生成モデルで評価すれば、閉じた循環になります。実世界のholdout、異なるシミュレータ、物理計測を組み合わせた検証が必要です。

6.6 scientific discoveryとGUI agent


科学では、分子、細胞、材料、気象などの状態変化を学び、仮説となる介入の結果を予測するモデルが「世界モデル」と呼ばれることがあります。ただし、物理法則を近似するsurrogate model、時系列予測、生成モデル、因果モデルの境界は曖昧です。科学用途では、当てはまりだけでなく保存則、単位、外挿、反証可能性が重要になります。

GUI agentでは、クリックや入力によって画面状態が変わります。画面を観測、操作を行動、DOMやアプリ状態を内部状態と考えれば、世界モデルで次画面を予測し、実行前に手順を検査できます。物理世界より規則的に見えますが、ログイン状態、ネットワーク遅延、権限、ポップアップなど部分観測性が強く、誤操作のコストもあります。

これらは本書の主役ではありませんが、世界モデルが「動画生成モデル」または「RL技法」だけに収まらないことを示します。

図6-1

模式図



実線＝知覚・予測・計画・行動の循環。破線＝学習更新／生成データへの利用。

表6-1 world modelの役割

役割	入力	出力	主な価値	主な失敗
representation	画像・センサー・履歴	latent / object state	状態推定、圧縮	重要な小物体や不確実性を捨てる
prediction	state + action	next state / observation	行動結果の予測	相関を因果と誤認する

役割	入力	出力	主な価値	主な失敗
planning	現在state＋候補action	score / selected action	現実の試行を減らす	モデル誤差を搾取する
simulator	初期条件＋agent action	interactive trajectory	安全な訓練・評価	ルールや状態が長期に崩れる
data generation	条件・prompt・scenario	synthetic trajectories	希少事象と多様性	偏りや物理矛盾を増幅する

表6-1の出典：Hou et al. (2026) のrobot learning整理、Ding et al.、Dong et al.を踏まえ、本書用に再構成（文献1・2・4）。

6.7 Multi-agent / Social Simulation

世界モデルの対象は物理環境だけとは限りません。交通、市場、組織、群集、オンライン空間では、複数主体の状態と行動、その相互作用を状態遷移としてモデル化できます。multi-agent simulationは、ある規則や制度の下で主体同士がどう影響し合うかを展開し、混雑、協調、競争、情報伝播などを調べる用途を持ちます。LLM agentsを用いるsimulationは、言語で表される役割、記憶、目標を持つ主体を組み込みやすく、この領域と接点があります。

ただし、social simulationを物理world modelと同一視することはできません。人間社会では、意図、規範、制度、権限、他者モデルが遷移へ入り、モデルの予測を見た人間が行動を変える反射性もあります。再現すべき法則が固定されず、同じ初期条件から同じ結果が出るとも限らないため、検証は物理法則型のモデルより難しくなります。

SocioVerseは、LLM agentsを使う社会シミュレーション基盤を「social world model」と位置づけ、調査データとの比較を試みたpreprintです（文献46）。これは世界モデルという語が社会的相互作用へ拡張されている例であり、社会の忠実な代替物が確立したことを意味しません。本節では用途の広がりだけを確認し、妥当性、反射性、価値判断の限界は8.10.7で扱います。

6.8 「使える」とは何か

世界モデルの価値は、利用者が何をしたいかで決まります。映像制作者にとっては高品質で操作可能な世界生成が価値です。ロボット制御では、見た目が粗くても接触と行動結果が正しいほうが価値があります。科学では、保存則と不確実性が重要です。

したがって、「このモデルは世界を理解したか」という一問だけでは評価できません。何を表現し、どの介入に答え、どの時間幅で正しく、どの意思決定を改善したかへ分解する必要があります。第8章でこの問題を詳しく扱います。

第7章 脳も世界モデルを持つのか

7.1 別の入口から「予測する内部モデル」へ

ここまで扱ったWorld Models、PlaNet、Dreamer、JEPAは、主に機械学習と強化学習から生まれた研究です。一方、認知科学・神経科学には、脳が感覚入力を受け身で処理するのではなく、内部モデルから予測し、予測誤差を使って知覚を更新するという研究系譜があります。(文献3・29・30・31・32)

両者には、観測から隠れた原因を推論する、内部状態から感覚を予測する、予測誤差で学ぶ、行動によって次の入力を変えるという共通語彙があります。そのため接続は魅力的です。しかし、同じ名称の部品が同じ数学的・生物学的意味を持つとは限りません。本章の目的は同一化ではなく、交差点を正確に見つけることです。

Taniguchi et al.は、認知・発達ロボティクスの観点から、world models、Predictive Coding、Free Energy Principle、Active Inferenceの定義と関係を整理しています。本章はその整理を主軸にします。(文献3)

7.2 Predictive Coding

7.2.1 予測と誤差が階層を往復する

Predictive Codingの基本的な直感は、上位層が下位層の活動を予測し、下位層は実際の入力との差、すなわち prediction errorを上位へ返すというものです。(文献29・31)

視覚を例にします。上位層が「ここには円形の物体がある」と予測すると、下位層の輪郭や色の活動を説明できません。予測で説明できた部分をすべて上へ送る必要はありません。予測から外れた輪郭、動き、色が誤差信号として強く伝わります。上位層はその誤差を小さくするよう内部状態を更新します。

RaoとBallard（1999）は、高次視覚野から低次視覚野へのfeedbackが低次活動の予測を伝え、feedforwardが予測と実活動の残差を伝える階層モデルを示しました。このモデルは、古典的受容野の外側から受ける影響の一部を機能的に説明しました。(文献29)

Predictive Codingを「脳は次の動画フレームを生成している」と理解するのは狭すぎます。予測対象は感覚入力の原因や階層的な神経活動であり、明示的な映像を意識内で描く必要はありません。また、予測誤差が小さければ常に良いわけでもありません。暗い部屋で目を閉じれば入力は予測しやすくなりますが、生物はそれだけを目指しているわけではありません。何を期待し、どの誤差を重く見るかが必要です。

7.2.2 prediction error minimization


予測誤差最小化では、内部状態を変えて観測をよりよく説明します。遠くの曖昧な影を人だと思ったが、近づいて木だと分かると、上位の仮説を更新します。誤差は単なる失敗ではなく、どの仮説を修正すべきかを教える信号です。

実際の理論では、誤差の大きさだけでなくprecision、すなわちその誤差をどれだけ信頼するかが重要です。雑音の多いセンサーの誤差と、精度の高いセンサーの誤差を同じ重みで扱うべきではありません。本書では数式へ進みま

せんが、世界モデルの不確実性と注意を考える入口になります。(文献3・31)

図7-1

模式図



下向き＝上位からの予測。上向き＝下位で説明できなかった残差。
破線＝各層の仮説更新。階層は説明用に三層へ簡略化。

7.3 Free Energy Principle

Free Energy Principle (FEP) は、予測符号化より広い枠組みです。Fristonの2005年の研究は、階層的生成モデルと経験ベイズによって感覚原因を推論する皮質応答の理論を提示しました。FristonとKiebel (2009) は、自由エネルギー原理の下でPredictive Codingを位置づけました。Friston (2010) は、知覚、学習、行動を統一的に捉える理論としてFEPをレビューしました。(文献30・31・32)

ここでいうsurpriseは「驚いた感情」ではなく、ある観測がモデルの下でどれほど起こりにくいかを表す情報量です。観測のsurpriseを直接計算するのは難しいため、それを上から押さえる変分自由エネルギーを最小化します。変分自由エネルギーは単純な平均二乗予測誤差とは異なり、特定の生成モデル・近似の下で予測誤差の形式として表されます。(文献30・31)

本書に必要な範囲では、次のように捉えれば十分です。

- ・ エージェントは感覚がどう生じるかという生成モデルを持つ
- ・ 感覚から、その原因となる隠れ状態を推論する
- ・ 内部状態やモデルを更新して、観測をよりよく説明する
- ・ 特定の定式化では、行動によって予測に合う感覚を生じさせることもできる

「自由エネルギー」という語は物理学の熱力学的自由エネルギーと関係を持ちますが、機械学習で使う変分自由エネルギーは確率モデルと推論における量です。両者を単純に「脳がエネルギー消費を減らす」と説明してはいけません。(文献32)

FEPは影響力のある統一的枠組みですが、脳機能のすべてが確立済みの事実として説明されたわけではありません。理論の一般性が非常に高いぶん、具体的な神経実装、反証可能性、経験的区別をめぐる議論があります。本書では「脳はFEPで動く」と断定せず、研究プログラムとして紹介します。(文献3・32)

7.4 Active Inference

予測と観測が合わないとき、エージェントには二つの方向があります。

1. **perceptual inference** : 内部の仮説を変え、実際の感覚を説明します。
2. **Active Inference** : 行動して、選好に合う結果へ近づき、情報を得て不確実性を減らします。(文献3・32)

たとえば目の前の果物が赤いか橙色か曖昧なら、照明や視点を変えて観測し直せます。これは受動的な認識ではなく、情報を得るための行動です。ロボットが物体の裏側へ回る、箱を少し持ち上げて重さを測る、音の方向へ首を向ける行為も同じ直感で考えられます。

Active Inferenceの代表的な定式化では、将来の方策をexpected free energyによって評価します。詳細を省けば、選好に沿う結果へ近づく価値と、不確実性を減らす情報価値の両方を含むと捉えられます。既知の安全経路を進むだけでなく、後の判断に必要な情報を得る探索を説明できる点が魅力です。(文献3・32)

強化学習との違いを「報酬を使うか使わないか」だけで切ると誤解します。標準的な強化学習は報酬と期待収益で方策を最適化します。Active Inferenceは、好ましい観測・状態へのprior preferenceと生成モデルの推論として行動を定式化します。両者にはcontrol as inferenceなど数学的接点がありますが、目的関数、意味づけ、典型的実装が異なります。(文献3・32)

7.5 機械学習world modelとの交差

共有する概念は多くあります。

- ・ 観測は世界状態の不完全な結果である
- ・ 隠れた状態を推論する内部モデルが必要である
- ・ 内部状態から将来の感覚や状態を予測する
- ・ 予測誤差によって表現やモデルを学ぶ
- ・ 行動は次の観測を変え、知覚と切り離せない

しかし、違いも大きいです。


- ・ Dreamerは工学的な強化学習アルゴリズムで、明示的な報酬とactor-criticを使います。(文献10・11・12)
- ・ JEPAは主に表現予測の学習アーキテクチャで、脳理論そのものではありません。(文献15・16・17・18)
- ・ Predictive Codingは神経階層における予測と誤差信号の理論です。(文献29)
- ・ FEP / Active Inferenceは生物の知覚・学習・行動を生成モデルと変分推論から記述しようとしています。(文献3・31・32)

したがって、Dreamer、JEPA、Active Inferenceを「三大世界モデル方式」として選択肢のように並べるのは不適切です。比較するなら、どの問題レベルを説明し、どの目的関数を用い、どの証拠で評価するかをそろえる必要があります。

Taniguchi et al.が示す重要な橋は、認知・発達ロボットが、身体と環境の相互作用から内部表現を継続的に学ぶという課題です。潜在表現、物体とaffordance、社会的他者、言語、cognitive architectureを、予測と行動の循環へ統合する必要があります。これは現代のPhysical AIが再び直面している問題でもあります。(文献3)

図7-2

模式図



右側の矢印＝本章の説明順。

歴史的な直接継承・理論の置換・同一性を示さない。

理論の目的と検証方法は異なる。共通語彙の共有は同一理論を意味しない。

7.6 脳は世界モデルを持つのか

この問いへの慎重な答えは、「予測的な内部モデルで説明できる知覚・行動現象があり、有力な理論と証拠があるが、単一の完成した世界モデルが脳内に格納されていると確定したわけではない」です。

予測的処理の研究では、感覚・運動・内受容など複数の系にまたがる階層的な生成モデルや、複数の時間尺度をもつ処理が論じられています。身体そのものの力学が計算を担い、明示的内部モデルを必要としない場面もあります。生物の知能を世界モデルだけで説明し切ろうとせず、予測モデル、身体、環境の結合として考えることが重要です。

第8章 世界モデルをどう評価するか、何がまだできないのか

8.1 評価は「何を主張したか」から始める

世界モデルの評価に万能な一つの点数はありません。未来画像を生成するモデル、潜在状態で方策を学ぶモデル、物体関係を推論するモデルでは、出力も目的も違います。評価は、モデルが何をできると主張したかに対応させる必要があります。

たとえば「高品質な動画生成」を主張するなら、視覚品質とテキスト条件への一致が中心になります。「物理世界を理解する」を主張するなら、物体永続性、連続性、衝突、因果、反事実を調べる必要があります。「ロボット計画に使える」を主張するなら、実機または独立した環境での成功率、安全性、モデル誤差の搾取を測るべきです。

低いレベルの評価結果から、高いレベルの主張へ飛ばないことが重要です。見た目の自然さは必要な証拠になりえますが、介入に対する正しさや意思決定有用性を単独では証明しません。

8.2 予測精度と状態精度

最も直接的なのは、予測と実際の差です。低次元状態なら、位置、速度、角度、接触、報酬などを一ステップと複数ステップで比較できます。ピクセル予測なら、画素誤差、知覚的類似度、動画分布の距離などを使います。

しかしピクセル誤差には問題があります。未来には複数の妥当な可能性があります。歩行者が右へ進むか左へ進むかを一つだけ正解にすると、妥当な別未来を罰します。反対に、全体が少しぼやけただけで大きな画素誤差が出て、車の軌道や衝突判定は正しいかもしれません。


そこで状態精度が重要になります。物体位置、姿勢、速度、個体同一性、接触関係など、世界の構造に近い量で測ります。ただし、何を状態とするかを人間が与えるため、汎用性との交換があります。

8.3 visual fidelityとphysical consistency

visual fidelityは、映像が鮮明で自然に見えるかを測ります。生成用途には本質的です。しかし、物理的一貫性とは分ける必要があります。

ボールが壁の手前から奥へ滑らかに消え、別の場所から現れる動画を考えます。局所的な画質と動きは自然でも、物体の永続性とsolidityに反します。逆に、解像度の低い点と線だけのシミュレーションでも、衝突と保存則が正しければ計画には有用です。

IntPhys 2（2025年プレプリント）は、複雑な合成動画で、物体のPermanence、Immutability、Spatio-Temporal Continuity、Solidityに対する直感物理を、期待違反の枠組みで評価します。モデルが「起こりうる動画」と「起こりえない動画」を区別できるかを見ることで、画質とは違う物理理解を測ります。同論文の評価設定では、多くの評価モデルが人間と大きな差を示しました。（文献33）



低 高
概念例を簡単な記号で表現。色・陰影は写実性の量的評価ではない。

8.4 action consistency

行動条件付きモデルでは、与えた行動が予測未来へ正しく反映される必要があります。LEFTとRIGHTを入れ替えてもほぼ同じ動画になるなら、動画として自然でも制御には使えません。

評価では、同じ初期状態から行動だけを変え、結果の差を見るべきです。自動運転なら操舵角と自車軌道、ロボットなら関節指令と手先・対象物の動き、ゲームならキー入力とavatarの反応を比較します。行動の強さ、順序、タイミングにも感度が必要です。

さらに、学習時に多かった行動だけでなく、境界や珍しい組合せを試します。プランナーは受動的なtest datasetと違い、モデルが楽観的に間違える行動を選びます。閉ループ評価では、このpolicy-induced distribution shiftを避けられません。

8.5 long-horizon consistency

一ステップ予測の小さな誤差は、rolloutで次の入力になります。位置が少しずれる、物体IDが入れ替わる、見えない物体を忘れる、ルールが徐々に変わる。長期予測では、こうした誤差が累積します。


1秒後と1分後は、単にステップ数が60倍という問題ではありません。短期では局所的な運動、長期では目標、イベント、記憶、階層的計画が支配します。細かいピクセルを60秒先まで固定する必要はない一方、「鍵を取った」「扉

が開いた」「物体を別室へ置いた」という状態は保持しなければなりません。

評価では、一ステップ平均だけでなく、1、5、10、25、50ステップなど複数horizonを報告します。観測誤差だけでなく、状態の逸脱、イベント順序、物体永続性、最終タスク成功を測ります。再計画で誤差を修正するclosed-loopと、途中で実観測を与えないopen-loopを分けます。

図8-2

模式図（実測ではない）



曲線は一般法則ではない。単調増加・鋸歯状・closed-loopの優位を保証しない。

毎時刻の実状態を入力する一歩予測評価と、closed-loop制御を区別する。

8.6 generalizationとdistribution shift

訓練と似た場면을再現できても、未知の物体、背景、視点、行動、身体へ対応できるとは限りません。世界モデルには、少なくとも次の一般化があります。

- 同じ規則で、物体の色や背景だけが変わる
- 物体数や配置の新しい組合せへ広がる
- 新しいタスクで同じダイナミクスを再利用する
- 別のロボット身体やセンサーへ移す
- 学習範囲外の速度、力、時間幅へ外挿する
- 別ドメインの共通知識を転移する

大規模事前学習は観測分布を広げますが、すべての介入を観察することはできません。物体中心表現、物理prior、階層表現、因果構造、online adaptationなどが候補ですが、単独の解決策はありません。

8.7 相関、因果、counterfactual

観測データから未来を当てるモデルは、相関だけでも高得点を取れます。雨天では傘を持つ人が多いことを学べば、傘から雨を予測できます。しかし「傘を閉じたら雨が止むか」という介入には答えられません。

世界モデルを計画に使うときは、行動を条件として候補未来を予測します。「もしブレーキを強く踏んだら」「もしこの箱を先に動かしたら」という、実際にはまだ起きていない未来を比較します。行動を外部から設定する制御では介入的な利用と捉えられますが、行動条件付き予測だけで因果効果の同定や一般的な因果理解が成立するわけではありません。因果効果として解釈するには、交絡などについての追加仮定が必要です。

counterfactualは、実際に観測された事実から背景条件を推論し、「実際にはaをしたが、同じ背景条件でa'をしていたらどうなったか」を問います。これは、同じ初期状態から複数の候補未来をrolloutするだけの比較とは異なります。実世界では片方しか観測できないため、構造的因果モデルや物理知識などの仮定と、シミュレータ・実験で検証できる範囲を明示する必要があります。

CausalVQA（2025年プレプリント）は、実世界動画についてdescriptive、anticipation、hypothetical、counterfactual、planningの質問を用意し、物理的因果推論を評価します。発表結果では、最先端のmultimodal modelも、とくにanticipationとhypotheticalで人間を大きく下回りました。同benchmarkの実世界video QAでは、将来の展開や仮想条件下の帰結を答える性能に、人間との差が残りました。（文献34）

8.8 planning utility

意思決定用の世界モデルに対する最終的な問いは、「そのモデルを使うと行動が良くなるか」です。

- ・ 目標達成率は上がるか
- ・ 実試行数は減るか
- ・ 失敗・衝突・制約違反は減るか
- ・ 未知環境でも効果が続くか
- ・ モデルなしの強いbaselineより良いか
- ・ 予測に自信がないとき、安全側へ動けるか
- ・ プランナーがモデルの誤差を悪用しないか

planning utilityが高ければ、画像再構成が粗くても有用な世界モデルです。MuZeroはこの点を鋭く示します。モデルは環境観測を忠実に再現せず、木探索に必要な報酬、価値、方策を予測します。（文献13）

ただし、タスク成功だけでも十分ではありません。簡単なshortcutで成功した可能性、特定環境へ過学習した可能性、安全性を犠牲にした可能性があります。予測指標とdownstream指標を組み合わせ、失敗時の内訳を調べます。

表8-1 世界モデルの評価軸

評価軸	代表的な問い	例となる測定	注意点
prediction accuracy	次状態をどれだけ当てるか	one-step / k-step error	複数の妥当未来を罰しうる
visual fidelity	映像が自然で鮮明か	FVD、知覚評価、人手評価	物理・因果の正しさを保証しない
state accuracy	位置・速度・接触が正しいか	trajectory、state error	正解stateの定義・注釈が必要

評価軸	代表的な問い	例となる測定	注意点
physical consistency	物体永続性や衝突が守られるか	IntPhys 2等	合成環境から実世界への一般化
action consistency	行動差が結果へ正しく反映されるか	行動条件を変えたpair、control sensitivity	テキスト条件とagent actionを区別。因果効果の同定とは別
long-horizon consistency	長時間で状態と規則を保つか	horizon別error、memory test	短期平均だけでは見えない
generalization	未知構成・身体・領域へ広がるか	OOD split、cross-embodiment	何を未知としたか明示する
causal reasoning	介入の効果を区別できるか	action intervention、causal QA	交絡・因果仮定を明示し、関連shortcutを排除
counterfactual reasoning	観測事実と同じ背景条件で別行動の結果を問えるか	paired simulation；video-based hypothetical / counterfactual QA（例：CausalVQA）	背景条件・因果仮定を明示。実世界の反事実正解は直接観測不能
planning utility	意思決定を実際に改善するか	task success、safety、sample efficiency	plannerによるmodel exploitation
uncertainty calibration	間違える可能性を正しく表すか	calibration、coverage、risk	平均精度が同じでも意思決定が変わる

表8-1の出典：Dong et al. (2026)、Hou et al. (2026)、IntPhys 2、CausalVQAを踏まえ、本書用に整理（文献2・4・33・34）。

8.9 general world modelは可能か

general world modelという言葉には、少なくとも三つの異なる目標が混ざります。

1. 多様な視覚世界を生成できる汎用生成モデル。
2. 多様な環境の状態遷移を表し、エージェントが対話できる汎用シミュレータ。
3. 新しい身体・タスク・法則へ適応し、因果推論と長期計画に使える汎用内部モデル。

第一の方向では大規模動画・3D生成が急速に進んでいます。第二ではGenieのような対話型環境とCosmosのようなPhysical AI基盤が現れました。第三はまだ遠い目標です。（文献20・21・22・24・25）

世界をすべて同じ解像度でモデル化するのは非効率です。人間も、投げたボールの軌道と10年後の社会を同じ方法で予測しません。将来の汎用モデルは、目的に応じて抽象度と時間尺度を変え、必要な部分だけを精密にシミュレートする階層構造になる可能性があります。

また、単一の巨大モデルがすべてを内部化するとは限りません。学習世界モデル、物理シミュレータ、検索可能な知識、因果モデル、記号的プランナー、外部ツールを組み合わせる構成も有力です。「General」を「単一ニューラルネットワーク」と同義にしないことが重要です。

8.10 未解決問題

現在の世界モデルが直面する課題をまとめます。

8.10.1 表現の十分性

何を残せば未知タスクにも十分かは分かりません。再構成に不要な小物体が安全に重要で、意味的に些細な時間差が接触の成否を変えます。

8.10.2 不確実性と複数未来

人間や他エージェントを含む世界は一意に決まりません。可能性の分布を表し、その不確実性を計画へ正しく伝える必要があります。

8.10.3 長期記憶と階層時間

フレーム生成だけでは、数分前の約束、別室に置いた物、達成済みのsubgoalを保てません。短期運動と長期イベントを異なる抽象度で扱う必要があります。

8.10.4 因果と介入

観測動画のscaleだけで、行動介入の効果を十分学べるかは未解決です。受動動画、ロボット軌跡、シミュレータ、実験データをどう組み合わせるかが課題です。

8.10.5 実時間性と計算量


高品質な動画を候補行動ごとに何本も生成する方法は、ロボット制御の周期に間に合わない可能性があります。潜在予測、蒸留、階層計画、必要部分だけの生成が重要です。

8.10.6 安全性と検証

世界モデルは現実の代用品であり、代用品の誤りが意思決定へ入ります。信頼度の低い状況で停止する、既知の物理・安全制約で監視する、独立したモデルでcross-checkするなど、system-levelの安全設計が必要です。

8.10.7 社会世界と価値

人間と協働するロボットは、物理だけでなく意図、規範、制度、権限、信頼を扱います。他者の内部状態を単純化しすぎると、誤解や不公平を生みます。さらに、予測やモデルの存在が人に知られることで、人々の行動と予測対象そのものが変わる反射性があります。予測できることと、行ってよいことを分けなければなりません。



周囲の六課題は意思決定の有用性に関わる。破線は課題間の因果同定を示さない。

8.11 本書の結論

世界モデルは、一つのモデル名でも、完成した単一技術でもありません。観測から内部状態を作り、時間と行動による変化を予測し、モデル内で未来を展開し、計画と行動へ使うという研究課題の束です。

2018年のWorld Modelsは、この課題を深層学習時代に鮮明に見せました。PlaNetとDreamerは潜在想像を意思決定へ結び、JEPAは予測対象をピクセルから表現へ移す道を示しました。大規模生成モデルは、見て操作できる世界を作る方向を加速し、物体中心モデルは構造と組合せ性を追求します。Predictive CodingとActive Inferenceは、知覚・推論・行動の循環を別の学問系譜から問い直します。(文献[3](#)・[7](#)・[9](#)・[10](#)・[15](#)・[20](#)・[26](#)・[29](#)・[32](#))

これから新しい研究を読むときは、「世界モデルか否か」というラベルだけを争う必要はありません。次の五問へ戻ってください。

1. 何を世界の状態として表現しているか。
2. 何を、どの時間幅で予測するか。
3. 行動による違いを扱えるか。
4. 予測をどの計画・行動へ使うか。
5. その主張を、どの評価が支えているか。

この五問こそが、研究名が変わっても使い続けられる「世界モデル研究の地図」です。

Appendix

A. 実行環境・付属実装

第5章の実測にはPython 3.11.6、PyTorch 2.5.1等を使用しました。直接依存はrequirements.txt、実行環境の固定情報はrequirements-lock.txtに記録しています。GPUは必須ではありません。付属実装はローカルCPUのfresh kernelで、seed11のBasic/Challenge、図、metricsまでNotebookを先頭から完走し、保存済み基準と照合しました。Notebookの非対話実行は、この環境での一回のwall実測で15.99秒、Notebook内部計測で15.33秒でした。加えて、MacBook (Apple M1、メモリ16GB) のarm64環境でも付属実装を実行し、`run_experiment.py --root reproduced_run` が正常終了することを確認しました。無料Google Colabでの現地実行・install時間・Notebook時間・total時間は未確認です。

配布物はmini_world_model_ch5_v02_release.zipと、同内容のrepository形式directoryです。主な構成は次のとおりです。セットアップ、Notebook/CLI、保存結果、テストの案内はREADME.mdを参照してください。

README.md : 案内・実行手順
mini_world_model.ipynb : 実行済みNotebook
mini_world_model.py / experiment.py : 共通module・実験処理
run_experiment.py : 主実験の一括実行
train.py / evaluate.py / plan.py : 学習・評価・planning
tests/ / results/ / figures/ : 検査・保存結果・図
SPEC.md / config.json : 実験仕様・設定
requirements.txt / requirements-lock.txt : 依存関係の記録

C. 原論文ロードマップ

C.1 world model / model-based RL

最短経路

1. Ha & Schmidhuber, “World Models” (初公開Preprint, 2018) / “Recurrent World Models Facilitate Policy Evolution” (同系列のNeurIPS掲載版, 2018) (文献7・8)
2. Hafner et al., “Learning Latent Dynamics for Planning from Pixels” (PlaNet, 2018/2019) (文献9)
3. Hafner et al., “Dream to Control: Learning Behaviors by Latent Imagination” (2019/2020) (文献10)
4. Hafner et al., “Mastering Atari with Discrete World Models” (DreamerV2, 2020/2021) (文献11)
5. Hafner et al., DreamerV3 : “Mastering Diverse Domains through World Models” (初公開Preprint, 2023) / “Mastering diverse control tasks through world models” (Nature掲載版, 2025) (文献12)

読む順序は、実装の細部より各論文のFigure 1、入力・予測target、行動の選び方、評価環境を先に追います。PlaNetはonline planning、Dreamerはlearned actorという差を確認します。

寄り道として重要

- Schrittwieser et al., MuZero (2019/2020) : 観測再構成なしで計画に必要な量を予測します。(文献13)
- Wu et al., DayDreamer (2022/2023) : Dreamerを実ロボットへ持ち込みます。(文献14)

C.2 JEPA

1. LeCun, “A Path Towards Autonomous Machine Intelligence” (2022, Position Paper) (文献15)
2. Assran et al., I-JEPA (2023) (文献16)
3. Bardes et al., V-JEPA (2024) (文献17)
4. Assran et al., V-JEPA 2 (2025) (文献18)

I-JEPAだけを読んでJEPA構想全体としないことが重要です。まず2022年文書で、world model、actor、cost、階層計画の関係を読み、その後の実装がどこまでを具体化したかを確認します。

C.3 generative worlds

1. video predictionの基礎研究を概観する
2. Hu et al., GAIA-1 (2023) (文献19)
3. Bruce et al., Genie (ICML, 2024) (文献20)
4. OpenAI, Sora technical report (2024) (文献23)
5. Google DeepMind, Genie 2 / Genie 3 research announcements (2024/2025) (文献21・22)
6. NVIDIA, Cosmos World Foundation Model Platform (2025) (文献24)

公開形態が混在します。論文でarchitectureと実験条件を確認できるもの、企業ページで主張とdemoだけが確認できるものを区別して読みます。

C.4 object-centric / structured

1. Kipf et al., C-SWM (初公開Preprint, 2019) (文献26)
2. Veerapaneni et al., OP3 (初公開Preprint, 2019 / CoRL論文集, 2020) (文献27)
3. Locatello et al., Slot Attention (2020) (文献28)

物体分割の見栄えだけでなく、未知の物体数・配置への一般化、遮蔽中のtracking、planningへの寄与を確認します。

C.5 Cognitive

1. Rao & Ballard, Predictive Coding (1999) (文献29)
2. Friston, “A Theory of Cortical Responses” (2005) (文献30)
3. Friston & Kiebel, Predictive Coding under FEP (2009) (文献31)
4. Friston, “The Free-Energy Principle: A Unified Brain Theory?” (2010) (文献32)
5. Taniguchi et al. (2023)でロボティクスとの接続を読む (文献3)

FEPの数式へ直行せず、prediction、inference、generative model、actionの用語が機械学習とどう同じでどう違うかを整理します。

D. 基幹サーベイ

D.1 S1：研究全体の背骨

Ding et al., “Understanding World or Predicting Future? A Comprehensive Survey of World Models.” arXiv:2411.14499; ACM Computing Surveys, DOI: 10.1145/3746449. (文献1) S1 / S2 / S3は本書内でのサーベイの役割ラベルであり、参考文献番号1 / 2 / 3とは別体系です。

D.2 S2：2026年の最新動向

Dong et al., “Learning to Model the World: A Survey of World Models in Artificial Intelligence.” [Preprints.org](https://preprints.org), 2026, DOI: 10.20944/preprints202603.0739.v1. (文献2)

観測レベル生成、潜在空間、RL-based、object-centricの整理と、応用・評価の広がり进行参照します。未査読preprintであり、四分類を排他的な四大流派とは扱いません。

D.3 S3：認知科学・ロボティクス

Taniguchi et al., “World Models and Predictive Coding for Cognitive and Developmental Robotics: Frontiers and Challenges.” Advanced Robotics 37(13), 780-806, 2023. DOI: 10.1080/01691864.2023.2225232. (文献3)

world model、prediction、inference、Umwelt、Predictive Coding、FEP、Active Inference、affordanceの関係を確認する主資料です。

D.4 Robotics補助サーベイ

Hou et al., “World Model for Robot Learning: A Comprehensive Survey.” arXiv:2605.00080, 2026. (文献4)

robot policy、learned simulator、robotic video world model、action consistency、long-horizon、評価の整理を補助的に使います。2026年のpreprintです。

Wang et al., “World Action Models: The Next Frontier in Embodied AI” (arXiv:2605.12090, 2026、文献42) は、VLAとworld dynamicsの接続をCascaded / Joint等の結合様式で整理する補助サーベイです。未査読preprintとして、第6章の接続方法を読む際に参照します。

E. 公開形態ラベル

本書では、最新研究を次のように表示します。

- **査読論文**：学会・journalで査読を経た版を確認できるもの
- **Preprint**：arXivやPreprints.orgで公開され、参照版について査読済みと確認できないもの
- **Position Paper**：実験的な完成モデルより、研究構想・立場を示すもの
- **Technical Report**：企業・研究組織による技術説明。再現に必要な詳細が限定される場合があるもの
- **Research Announcement / Product**：公開demo、blog、サービス説明が主資料であるもの

同じ研究がpreprintから査読論文へ進む場合は、初回公開年と査読版の年を必要に応じ併記します。

編集後記

- 本書作成にはChatGPT/Plusライセンスを用いております
 - いわゆるポンだしではまだ駄目ですね。数十回指示と確認を繰り返しました

大まかな作成流れ

1. GPT-5.6 Sol / Chatと、章立て・研究地図・本全体の方針を検討
2. GPT-5.6 Solの高推論設定 / Workで最初の長文原稿を作成
3. GPT-6 Astra / Workでも別案を作成
 - 原案から時期が空いてしまいまたLLM更新があり再作成してみた
4. Chatで両案を比較し、SOL稿をcanonical masterの基礎として選択
 - 作り方にもよりますが、事実関係はAstra, 全体としてはSolが良いということでSolベースにAstra内容をマージ
5. Workで良い部分だけを評価・移植し、段階的にcanonical masterを更新
6. Codexで第5章の実装・実測・テストを行い、結果をWorkで本文へ反映
7. Deep ResearchやWorkによるWeb調査で最新研究・引用・参考文献を監査
8. Workで図版23点、引用整備、公開物、Markdown canonical化まで実施
9. 最後はGPT-5.6 Sol / Chatで内容・表現・レイアウトを何度も確認・修正

役割分担

原案と計画、そして原稿確認は、aokikenichi。計画・調査・作図・執筆・修正・表紙はChatGPTです。

- **企画・構成・編集判断・細部修正・表紙案**
 - GPT-5.6 Sol High / Chat
 - 章立て、研究地図、説明方針、2案の比較、文章の細部、レイアウト判断など
- **追加調査・事実確認**
 - GPT-5.6 Sol High / Chat + Deep Research
 - 論文・一次資料・最新研究の確認
 - ただし後半の最新研究差分調査や引用監査には、Work側での調査もかなり入っている
 - 実際、最新研究更新ではV-JEPA 2.1、Cosmos、Genie、World Model×Policyなどを調査した上で、全面書き換えではなく限定更新しています。『世界モデル入門』v0.2-edit2a 最新研究差分調査
- **長文執筆・大規模編集・監査・図版制作**
 - GPT-5.6 Sol / GPT-6 Astra の高推論設定 / Work
 - v0.1原稿作成
 - SOL稿とAstra系稿の比較
 - canonical master化
 - 全文編集、最新研究反映、23図制作、引用監査、Markdown移行など
 - 図版23点は最終的にPython/SVG/Matplotlibで制作しており、画像生成AIではありません。世界モデル入門_v0.2-edit3a_Step11受入検査...

- Markdown移行もPandoc+移行script+機械QAというかなり「Work的」な工程でした。
migration_report

- **実装・実験・テスト**

- GPT-5.6 Sol / GPT-6 Astra の高推論設定 / Codex
 - 第5章 Mini World Model
 - 学習・評価・MPC実験
 - failure case検証
 - Notebook、tests、公開用package整備

改訂履歷

- 2026-10-04 v0.3 Public Beta

参考文献・一次資料

公開形態と版情報は各項目の注記に保持しています。企業公式発表、product、prototype、preprintを査読論文と同一視しません。

1. Ding, J. et al. “Understanding world or predicting future? A comprehensive survey of world models.” ACM Computing Surveys, 58(3), pp. 1-38. 2025. DOI: [10.1145/3746449](https://doi.org/10.1145/3746449). 注記 : arXiv:2411.14499. [↩1](#) [↩2](#)
2. Dong, J. et al. “Learning to model the world: A survey of world models in artificial intelligence.” 2026. DOI: [10.20944/preprints202603.0739.v1](https://doi.org/10.20944/preprints202603.0739.v1). <https://www.preprints.org/manuscript/202603.0739>. 注記 : Preprints.org version 1; not peer reviewed. [↩1](#) [↩2](#) [↩3](#)
3. Taniguchi, T. et al. “World models and predictive coding for cognitive and developmental robotics: Frontiers and challenges.” Advanced Robotics, 37(13), pp. 780-806. 2023. DOI: [10.1080/01691864.2023.2225232](https://doi.org/10.1080/01691864.2023.2225232). 注記 : arXiv:2301.05832. [↩1](#) [↩2](#) [↩3](#) [↩4](#) [↩5](#) [↩6](#) [↩7](#) [↩8](#) [↩9](#) [↩10](#) [↩11](#) [↩12](#) [↩13](#) [↩14](#)
4. Hou, B. et al. “World model for robot learning: A comprehensive survey.” 2026. <https://arxiv.org/abs/2605.00080>. 注記 : preprint. [↩1](#) [↩2](#) [↩3](#)
5. Sutton, R.S.; Barto, A.G. “Reinforcement learning: An introduction.” MIT Press. 2018. <http://incompleteideas.net/book/the-book-2nd.html>. [↩1](#)
6. Sutton, R.S. “Integrated architectures for learning, planning, and reacting based on approximating dynamic programming.” Proceedings of the seventh international conference on machine learning, pp. 216-224. 1990. <http://incompleteideas.net/papers/sutton-90.pdf>. [↩1](#) [↩2](#)
7. Ha, D.; Schmidhuber, J. “World models.” 2018. <https://arxiv.org/abs/1803.10122v1>. 注記 : first posted 2018-03-27; project: <https://worldmodels.github.io/>. [↩1](#) [↩2](#) [↩3](#) [↩4](#) [↩5](#) [↩6](#) [↩7](#) [↩8](#) [↩9](#) [↩10](#) [↩11](#) [↩12](#)
8. Ha, D.; Schmidhuber, J. “Recurrent world models facilitate policy evolution.” Advances in neural information processing systems 31, pp. 2451-2463. 2018. <https://papers.neurips.cc/paper/7512-recurrent-world-models-facilitate-policy-evolution>. 注記 : peer-reviewed paper in the same research line as Reference 7. [↩1](#) [↩2](#) [↩3](#) [↩4](#) [↩5](#) [↩6](#) [↩7](#) [↩8](#) [↩9](#) [↩10](#)
9. Hafner, D.; Lillicrap, T.; Fischer, I.; Villegas, R.; Ha, D.; Lee, H.; Davidson, J. “Learning latent dynamics for planning from pixels.” Proceedings of the 36th international conference on machine learning, PMLR, 97, pp. 2555-2565. 2019. <https://proceedings.mlr.press/v97/hafner19a.html>. 注記 : PlaNet; first preprint 2018. [↩1](#) [↩2](#) [↩3](#) [↩4](#) [↩5](#) [↩6](#) [↩7](#)
10. Hafner, D.; Lillicrap, T.; Ba, J.; Norouzi, M. “Dream to control: Learning behaviors by latent imagination.” International conference on learning representations. 2020. <https://arxiv.org/abs/1912.01603>. 注記 : first preprint 2019. [↩1](#) [↩2](#) [↩3](#) [↩4](#) [↩5](#) [↩6](#) [↩7](#) [↩8](#) [↩9](#) [↩10](#) [↩11](#) [↩12](#) [↩13](#)
11. Hafner, D.; Lillicrap, T.; Norouzi, M.; Ba, J. “Mastering atari with discrete world models.” International conference on learning representations. 2021. <https://arxiv.org/abs/2010.02193>. 注記 : first preprint 2020. [↩1](#) [↩2](#) [↩3](#) [↩4](#) [↩5](#) [↩6](#) [↩7](#)
12. Hafner, D. et al. “Mastering diverse control tasks through world models.” Nature, 640, pp. 647-653. 2025. DOI: [10.1038/s41586-025-08744-2](https://doi.org/10.1038/s41586-025-08744-2). 注記 : initial preprint title: Mastering Diverse Domains through World Models, arXiv:2301.04104v1, 2023-01-10. [↩1](#) [↩2](#) [↩3](#) [↩4](#) [↩5](#) [↩6](#) [↩7](#)
13. Schrittwieser, J. et al. “Mastering atari, go, chess and shogi by planning with a learned model.” Nature, 588, pp. 604-609. 2020. DOI: [10.1038/s41586-020-03051-4](https://doi.org/10.1038/s41586-020-03051-4). 注記 : first preprint 2019. [↩1](#) [↩2](#) [↩3](#) [↩4](#) [↩5](#)

14. Wu, P.; Escontrela, A.; Hafner, D.; Abbeel, P.; Goldberg, K. “DayDreamer: World models for physical robot learning.” Proceedings of the conference on robot learning, PMLR, 205, pp. 2226-2240. 2023.
<https://proceedings.mlr.press/v205/wu23c.html>. 注記 : CoRL 2022; arXiv:2206.14176. ↩1 ↩2
15. LeCun, Y. “A path towards autonomous machine intelligence.” 2022. <https://openreview.net/forum?id=BZ5a1r-kVsf>. 注記 : position paper. ↩1 ↩2 ↩3 ↩4 ↩5 ↩6 ↩7 ↩8
16. Assran, M.; Duval, Q.; Misra, I.; Bojanowski, P.; Vincent, P.; Rabbat, M.; LeCun, Y.; Ballas, N. “Self-supervised learning from images with a joint-embedding predictive architecture.” IEEE/CVF conference on computer vision and pattern recognition. 2023. <https://arxiv.org/abs/2301.08243>. ↩1 ↩2 ↩3 ↩4 ↩5 ↩6 ↩7
17. Bardes, A. et al. “Revisiting feature prediction for learning visual representations from video.” Transactions on Machine Learning Research. 2024. <https://openreview.net/forum?id=QaCCuDfBk2>. 注記 : arXiv:2404.08471; official code and weights: <https://github.com/facebookresearch/jepa>. ↩1 ↩2 ↩3 ↩4 ↩5 ↩6
18. Assran, M. et al. “V-JEPA 2: Self-supervised video models enable understanding, prediction and planning.” 2025. <https://arxiv.org/abs/2506.09985v1>. 注記 : numerical reference version posted 2025-06-11; official code and checkpoints: <https://github.com/facebookresearch/vjepa2>. ↩1 ↩2 ↩3 ↩4 ↩5 ↩6 ↩7 ↩8
19. Hu, A.; Russell, L.; Yeo, H.; Murez, Z.; Fedoseev, G.; Kendall, A.; Shotton, J.; Corrado, G. “GAIA-1: A generative world model for autonomous driving.” Wayve. 2023. <https://arxiv.org/abs/2309.17080>. 注記 : technical report. ↩1 ↩2 ↩3 ↩4 ↩5
20. Bruce, J. et al. “Genie: Generative interactive environments.” Proceedings of the 41st international conference on machine learning, PMLR, 235, pp. 4603-4623. 2024. <https://proceedings.mlr.press/v235/bruce24a.html>. 注記 : arXiv:2402.15391; Google DeepMind publication 60474. ↩1 ↩2 ↩3 ↩4 ↩5 ↩6 ↩7
21. Google DeepMind. “Genie 2: A large-scale foundation world model.” 2024.
<https://deepmind.google/blog/genie-2-a-large-scale-foundation-world-model/>. 注記 : research announcement. ↩1 ↩2 ↩3 ↩4 ↩5 ↩6
22. Google DeepMind. “Genie 3: A new frontier for world models.” 2025. <https://deepmind.google/blog/genie-3-a-new-frontier-for-world-models/>. 注記 : research announcement. ↩1 ↩2 ↩3 ↩4 ↩5
23. OpenAI. “Video generation models as world simulators.” OpenAI. 2024. <https://openai.com/index/video-generation-models-as-world-simulators/>. 注記 : technical report. ↩1 ↩2 ↩3 ↩4 ↩5
24. NVIDIA et al. “Cosmos world foundation model platform for physical AI.” 2025.
<https://arxiv.org/abs/2501.03575>. 注記 : initial Cosmos platform paper. ↩1 ↩2 ↩3 ↩4 ↩5 ↩6 ↩7
25. World Labs. “Marble: A multimodal world model.” 2025. <https://www.worldlabs.ai/blog/marble-world-model>. 注記 : product and research announcement; World API and release notes are supplementary links. ↩1 ↩2 ↩3 ↩4
26. Kipf, T.; Pol, E.; Welling, M. “Contrastive learning of structured world models.” 2019.
<https://arxiv.org/abs/1911.12247>. 注記 : preprint first posted 2019-11-27; code: <https://github.com/tkipf/c-swm>. ↩1 ↩2 ↩3
27. Veerapaneni, R.; Co-Reyes, J.D.; Chang, M.; Janner, M.; Finn, C.; Wu, J.; Tenenbaum, J.B.; Levine, S. “Entity abstraction in visual model-based reinforcement learning.” Proceedings of the conference on robot learning, PMLR, 100, pp. 1439-1456. 2020. <https://proceedings.mlr.press/v100/veerapaneni20a.html>. 注記 : arXiv:1910.12827 first posted in 2019. ↩1 ↩2 ↩3 ↩4
28. Locatello, F. et al. “Object-centric learning with slot attention.” Advances in neural information processing systems 33, pp. 11525-11538. 2020.
<https://proceedings.neurips.cc/paper/2020/hash/8511df98c02ab60aea1b2356c013bc0f-Abstract.html>. ↩1 ↩2

29. Rao, R.P.N.; Ballard, D.H. "Predictive coding in the visual cortex: A functional interpretation of some extra-classical receptive-field effects." *Nature Neuroscience*, 2(1), pp. 79-87. 1999. DOI: [10.1038/4580](https://pubmed.ncbi.nlm.nih.gov/10195184/).
<https://pubmed.ncbi.nlm.nih.gov/10195184/>. ↩1 ↩2 ↩3 ↩4 ↩5 ↩6 ↩7
30. Friston, K. "A theory of cortical responses." *Philosophical Transactions of the Royal Society B: Biological Sciences*, 360(1456), pp. 815-836. 2005. DOI: [10.1098/rstb.2005.1622](https://doi.org/10.1098/rstb.2005.1622). ↩1 ↩2 ↩3 ↩4 ↩5
31. Friston, K.; Kiebel, S. "Predictive coding under the free-energy principle." *Philosophical Transactions of the Royal Society B: Biological Sciences*, 364(1521), pp. 1211-1221. 2009. DOI: [10.1098/rstb.2008.0300](https://doi.org/10.1098/rstb.2008.0300). ↩1 ↩2 ↩3 ↩4 ↩5 ↩6 ↩7 ↩8
32. Friston, K. "The free-energy principle: A unified brain theory?." *Nature Reviews Neuroscience*, 11(2), pp. 127-138. 2010. DOI: [10.1038/nrn2787](https://doi.org/10.1038/nrn2787). ↩1 ↩2 ↩3 ↩4 ↩5 ↩6 ↩7 ↩8 ↩9 ↩10 ↩11
33. Bordes, F.; Garrido, Q.; Kao, J.T.; Williams, A.; Rabbat, M.; Dupoux, E. "IntPhys 2: Benchmarking intuitive physics understanding in complex synthetic environments." 2025. <https://arxiv.org/abs/2506.09849>. 注記 : preprint. ↩1 ↩2
34. Foss, A.; Evans, C.; Mitts, S.; Sinha, K.; Rizvi, A.; Kao, J.T. "CausalVQA: A physically grounded causal reasoning benchmark for video models." 2025. <https://arxiv.org/abs/2506.09943>. 注記 : preprint. ↩1 ↩2
35. Mur-Labadia, L.; Muckley, M.; Bar, A.; Assran, M.; Sinha, K.; Rabbat, M.; LeCun, Y.; Ballas, N.; Bardes, A. "V-JEPA 2.1: Unlocking dense features in video self-supervised learning." 2026.
<https://arxiv.org/abs/2603.14482v3>. 注記 : v3 dated 2026-06-11; v1 dated 2026-03-15. ↩1 ↩2 ↩3
36. Google DeepMind; Google. "Project genie: Experimenting with infinite, interactive worlds." 2026.
<https://blog.google/innovation-and-ai/models-and-research/google-deepmind/project-genie/>. 注記 : experimental research prototype and product announcement, 2026-01-29. ↩1 ↩2
37. NVIDIA et al. "World simulation with video foundation models for physical AI." 2026.
<https://arxiv.org/abs/2511.00062v2>. 注記 : Cosmos Predict 2.5 technical report; v2 dated 2026-02-24; v1 dated 2025-10-28. ↩1 ↩2 ↩3
38. NVIDIA et al. "Cosmos 3: Omnimodal world models for physical AI." NVIDIA. 2026.
<https://arxiv.org/abs/2606.02800v4>. 注記 : v4 dated 2026-06-23; v1 dated 2026-06-01. ↩1 ↩2 ↩3
39. World Labs. "Atlas: A world model for spatial intelligence." 2026. <https://www.worldlabs.ai/blog/atlas>. 注記 : official research announcement and early access, 2026-09-01; no peer-reviewed paper confirmed. ↩1 ↩2
40. Zheng, R. et al. "FLARE: Robot learning with implicit world modeling." *Proceedings of the conference on robot learning*, PMLR, 305, pp. 3952-3971. 2025. <https://proceedings.mlr.press/v305/zheng25a.html>. ↩1 ↩2
41. Huang, Y. et al. "LaDi-WM: A latent diffusion-based world model for predictive manipulation." *Proceedings of the conference on robot learning*, PMLR, 305, pp. 1726-1743. 2025.
<https://proceedings.mlr.press/v305/huang25a.html>. ↩1 ↩2
42. Wang, S. et al. "World action models: The next frontier in embodied AI." 2026.
<https://arxiv.org/abs/2605.12090v1>. 注記 : preprint first posted 2026-05-12. ↩1
43. Tolman, E.C. "Cognitive maps in rats and men." *Psychological Review*, 55(4), pp. 189-208. 1948. DOI: [10.1037/h0061626](https://doi.org/10.1037/h0061626). 注記 : added in Step 12 for the cognitive-map source claim. ↩1
44. Kalman, R.E. "A new approach to linear filtering and prediction problems." *Journal of Basic Engineering*, 82(1), pp. 35-45. 1960. DOI: [10.1115/1.3662552](https://doi.org/10.1115/1.3662552). 注記 : added in Step 12 for the Kalman-filter source claim. ↩1
45. Uexküll, J. "A foray into the worlds of animals and humans: With a theory of meaning." University of Minnesota Press. 2010. <https://www.upress.umn.edu/9780816659005/a-foray-into-the-worlds-of-animals-and-humans/>.
注記 : standard English translation; original German work published 1934; added in Step 12 for Umwelt. ↩1 ↩2

46. Zhang, X. et al. "SocioVerse: A world model for social simulation powered by LLM agents and a pool of 10 million real-world users." 2025. DOI: [10.48550/arXiv.2504.10157](https://doi.org/10.48550/arXiv.2504.10157). <https://arxiv.org/abs/2504.10157v3>. 注記 : preprint; v3 dated 2025-07-15; added in v0.3 as a cautious example of LLM-agent-based social simulation using world-model terminology. ↩1